



Universidad de Oviedo

Facultad de Ciencias

Grado en Matemáticas

---

**SIMILITUDES BASADAS EN  
INCRUSTACIONES PARA DATOS  
INTERVALARES**

Alfredo Vázquez Estrada

Junio de 2026

---

Dirigido por  
Pedro Huidobro Fernández

De acuerdo con lo expresado en el artículo 8.3 del Reglamento sobre la asignatura Trabajo Fin de Grado en la Universidad de Oviedo, aprobado por su Consejo de Gobierno el 5 de marzo de 2020 (BOPA de 30 de marzo de 2020), quiero expresar lo siguiente:

Yo, Alfredo Vázquez Estrada, con NIF 71748269E, en relación con la memoria que presento ante el Tribunal, para su valoración como Trabajo Fin de Grado, quiero DECLARAR que soy el autor de la misma, habiendo citado debidamente las fuentes utilizadas en su desarrollo.

Para que conste, firmo el presente documento.

En Oviedo, a 29 de mayo de 2026

Fdo.

# Índice general

|                                                                             |           |
|-----------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                      | <b>3</b>  |
| 1.1. Motivación . . . . .                                                   | 3         |
| 1.2. Objetivos . . . . .                                                    | 4         |
| 1.3. Estructura del trabajo . . . . .                                       | 5         |
| <b>2. Conceptos básicos</b>                                                 | <b>6</b>  |
| <b>3. Medidas de incrustación para intervalos</b>                           | <b>12</b> |
| 3.1. Incrustación basada en la amplitud de los intervalos . . . . .         | 13        |
| 3.2. Incrustaciones basadas en implicaciones . . . . .                      | 15        |
| <b>4. Similitudes basadas en medidas de incrustación</b>                    | <b>23</b> |
| 4.1. $\sqcup$ –Similitudes basadas en medidas de incrustación . . . . .     | 26        |
| <b>5. Aplicación a series temporales intervalares</b>                       | <b>42</b> |
| 5.1. Series temporales: fundamento teórico . . . . .                        | 42        |
| 5.1.1. Definición y conceptos básicos . . . . .                             | 42        |
| 5.1.2. ARIMA . . . . .                                                      | 46        |
| 5.1.3. Series temporales difusas . . . . .                                  | 49        |
| 5.2. Método para FTS intervalares . . . . .                                 | 52        |
| 5.2.1. Ejemplo 1: predicción de temperaturas . . . . .                      | 55        |
| 5.2.2. Ejemplo 2: predicción del precio diario de la electricidad . . . . . | 61        |
| <b>6. Conclusiones</b>                                                      | <b>72</b> |
| <b>Bibliografía</b>                                                         | <b>74</b> |

# Capítulo 1

## Introducción

### 1.1. Motivación

Uno de los objetivos principales de las matemáticas y la estadística es modelizar situaciones de la realidad con el fin de identificar patrones subyacentes y anticipar eventos futuros. Para ello, resulta fundamental recoger datos que aporten información sobre el contexto y el entorno experimental. Ahora bien, en muchas ocasiones, esos datos no son exactos, sino que incorporan cierto grado de incertidumbre, bien porque el instrumento con el que se obtienen no es perfecto, bien porque la magnitud observada es demasiado cualitativa o imprecisa como para representarse numéricamente de manera unívoca.

Esta problemática propició el nacimiento de la lógica difusa (*fuzzy logic*), introducida por Lotfi A. Zadeh en 1965 [28]. Este campo constituye una extensión de la lógica booleana clásica, ya que permite considerar situaciones intermedias que no pueden describirse únicamente mediante los grados de pertenencia tradicionales 0 y 1. Dentro de la lógica difusa existen múltiples formas de representar la incertidumbre, y una de las más utilizadas es el empleo de intervalos. Los intervalos constituyen una herramienta especialmente útil, pues permiten modelizar situaciones en las que representar una magnitud mediante un único número resulta insuficiente y es necesario incorporar cierto grado de imprecisión.

Para llevar a cabo un tratamiento adecuado de la incertidumbre mediante intervalos, es necesario desarrollar herramientas que permitan trabajar con ellos de forma rigurosa,

teniendo en cuenta aspectos como sus extremos o su amplitud. Por ejemplo, resulta natural extender nociones clásicas como la relación de contenido, de manera que no solo se contemple si un intervalo está o no contenido en otro, sino también el grado en que dicha inclusión se produce. En este contexto surgen las incrustaciones [7], operadores que permiten cuantificar el grado de contención de un intervalo en otro.

Otro elemento clave son las medidas de similitud [22], funciones que cuantifican numéricamente el parecido entre dos elementos, en este caso intervalos. Existen numerosas formas de definir este tipo de medidas, con distintas motivaciones y propiedades. Este trabajo se centrará en aquellas que se construyen a partir de incrustaciones, utilizando funciones de agregación [2]. La idea fundamental consiste en medir la semejanza entre dos intervalos a partir del grado en que cada uno está contenido en el otro, lo que proporciona una forma natural de comparar ambos objetos.

El estudio de la lógica difusa intervalar ha despertado un notable interés debido a su aplicabilidad en diversos campos. Entre ellos destaca la extensión de algoritmos de análisis de datos y pronóstico al caso en que las observaciones son intervalos. En muchas situaciones resulta conveniente trabajar con cierto grado de imprecisión, mientras que los métodos tradicionales no siempre ofrecen una forma directa de incorporarla.

## 1.2. Objetivos

El objetivo de este trabajo es construir, analizar y estudiar las propiedades de las incrustaciones y de las similitudes obtenidas a partir de ellas, para posteriormente aplicarlas a un problema concreto de análisis de datos. En particular, se plantean los siguientes objetivos:

- Definir el concepto de incrustación para intervalos, estudiar cómo extiende la relación clásica de contenido al caso difuso y presentar varios métodos de construcción de estos operadores.
- Obtener operadores de similitud a partir de dichas incrustaciones, analizar sus propiedades e identificar algunas de sus limitaciones.
- Explorar cómo, mediante el uso de la envolvente convexa [16], pueden construirse nuevas similitudes capaces de tratar de forma más informativa situaciones en las que los intervalos no se solapan.

- Aplicar las similitudes basadas en incrustaciones a un algoritmo de series temporales difusas intervalares y comparar su desempeño con el de métodos clásicos como ARIMA.

### 1.3. Estructura del trabajo

Para alcanzar los objetivos anteriores, el trabajo se estructura de la siguiente forma:

- En el **Capítulo 2**, se introducen los conceptos básicos necesarios para el desarrollo de los capítulos posteriores. Se presentan relaciones de orden, nociones de monotonía de funciones, funciones de agregación, t-normas y funciones de similitud.
- En el **Capítulo 3**, se presentan las medidas de incrustación para intervalos. Se definen de forma axiomática y se estudian dos familias principales: las basadas en la amplitud de los intervalos y las construidas a partir de funciones de implicación.
- En el **Capítulo 4**, se desarrollan las similitudes basadas en incrustaciones, analizando su construcción, sus propiedades y sus limitaciones. Además, se propone una extensión basada en la envolvente convexa, dando lugar a las similitudes  $\sqcup$ -agregadas. Se estudiará cómo estas nuevas medidas permiten asignar grados de semejanza no triviales en situaciones en las que las similitudes originales resultan poco informativas, especialmente para intervalos disjuntos y, bajo hipótesis adicionales, para intervalos degenerados.
- En el **Capítulo 5**, se aplican estos operadores al contexto de las series temporales. En primer lugar, se introducen conceptos generales sobre series temporales, modelos ARIMA y series temporales difusas. A continuación, se desarrolla el algoritmo propuesto para series temporales intervalares. Este se evalúa en dos conjuntos de datos, uno relativo a temperaturas y otro a precios de la electricidad, y se comparan los resultados obtenidos con los de métodos clásicos.
- En el **Capítulo 6**, se exponen las principales conclusiones del trabajo y se proponen posibles líneas futuras de investigación.

# Capítulo 2

## Conceptos básicos

En este capítulo se introducen los conceptos que servirán de base para los desarrollos posteriores, así como la notación que se utilizará a lo largo del trabajo. Comenzando por esto último:

**Notación 2.1.** Se denota por  $\mathcal{L}([0, 1])$  a la familia de intervalos cerrados contenidos en  $[0, 1]$ .

$$\mathcal{L}([0, 1]) = \{[\underline{a}, \bar{a}] \mid \underline{a}, \bar{a} \in [0, 1] \text{ y } \underline{a} \leq \bar{a}\}.$$

**Notación 2.2.** Dado un intervalo  $a = [\underline{a}, \bar{a}] \in \mathcal{L}([0, 1])$ , su amplitud se denota como  $w(a) = \bar{a} - \underline{a}$ .

Un primer concepto que resulta importante recordar es la idea de relación de orden.

**Definición 2.1.** [24] Dado un conjunto  $X$  y una relación binaria  $\mathcal{R}$ , se dice que  $\mathcal{R}$  es una relación de orden sobre  $X$  si verifica las siguientes propiedades:

1. Reflexiva: para todo  $a \in X$ ,  $a\mathcal{R}a$ .
2. Antisimétrica: dados  $a, b \in X$  tales que  $a\mathcal{R}b$  y  $b\mathcal{R}a$ , entonces  $a = b$ .
3. Transitiva: dados  $a, b$  y  $c \in X$  tales que  $a\mathcal{R}b$  y  $b\mathcal{R}c$ , se cumple que  $a\mathcal{R}c$ .

Además, se dice que ese orden es total si para cualquier par  $a, b \in X$ , se tiene necesariamente que  $a\mathcal{R}b$  o  $b\mathcal{R}a$ . Si esto no se da, el orden se conoce como parcial.

Algunos ejemplos son el contenido entre conjuntos (orden parcial) o el orden usual de los números naturales (orden total). En nuestro caso, al estar trabajando con intervalos, se considerarán las siguientes relaciones de orden parcial:

**Definición 2.2.** [7] Dados  $a, b \in \mathcal{L}([0, 1])$ :

- $a$  está contenido en  $b$  ( $a \subseteq b$ ) si y solo si  $\underline{b} \leq \underline{a} \leq \bar{a} \leq \bar{b}$ .
- $a$  es menor que  $b$  (orden reticular,  $a \preceq_{Lo} b$ ) si y solo si  $\underline{a} \leq \underline{b}$  y  $\bar{a} \leq \bar{b}$ .

Las dos son relevantes, pero el grueso del trabajo se basará en la primera de ellas.

La monotonía de las funciones será un concepto relevante a lo largo de este trabajo. Por ello, a continuación se introduce la terminología que se empleará al tratar esta propiedad.

**Definición 2.3.** [11] Dada una función  $f : [0, 1]^n \rightarrow [0, 1]$ , se dice que  $f$  es:

- creciente en el argumento  $i$  si dados  $(x_1, \dots, x_i, \dots, x_n), (x_1, \dots, y_i, \dots, x_n) \in [0, 1]^n$  tales que  $x_i \leq y_i$ , entonces  $f(x_1, \dots, x_i, \dots, x_n) \leq f(x_1, \dots, y_i, \dots, x_n)$ ,
- estrictamente creciente en el argumento  $i$  si dados  $(x_1, \dots, x_i, \dots, x_n), (x_1, \dots, y_i, \dots, x_n) \in [0, 1]^n$  tales que  $x_i < y_i$ , entonces  $f(x_1, \dots, x_i, \dots, x_n) < f(x_1, \dots, y_i, \dots, x_n)$ ,
- estrictamente creciente en conjunto si para todo  $(x_1, \dots, x_n), (y_1, \dots, y_n) \in [0, 1]^n$  tales que  $x_i < y_i$  para todo  $i \in \{1, \dots, n\}$ , entonces  $f(x_1, \dots, x_n) < f(y_1, \dots, y_n)$ .

Como se ha mencionado previamente, uno de los objetivos principales de este trabajo es proporcionar medidas de similitud que permitan comparar intervalos. Una herramienta relevante para lograrlo son las funciones de agregación, cuya definición y propiedades más relevantes se presentan a continuación.

**Definición 2.4.** [2, 3] Una función  $\mathcal{A} : [0, 1]^n \rightarrow [0, 1]$  se llama función de agregación si satisface las siguientes propiedades:

- A1) Condiciones de frontera:  $\mathcal{A}(0, \dots, 0) = 0$  y  $\mathcal{A}(1, \dots, 1) = 1$ .
- A2) Creciente en cada componente. Dados  $x, y \in [0, 1]^n$  con  $x = (x_1, \dots, x_n), y = (y_1, \dots, y_n)$ , tales que  $x_i \leq y_i \quad \forall i \in \{1, \dots, n\}$ , se tiene que  $\mathcal{A}(x) \leq \mathcal{A}(y)$ .

Su propósito principal es combinar una serie de puntuaciones, notas o valoraciones de un grupo de objetos y así resumir esa información mediante un único número.

**Ejemplo 2.1.** Algunas funciones de agregación comúnmente utilizadas son las siguientes:

- Media aritmética:  $\mathcal{A}(x_1, \dots, x_n) = \frac{x_1 + \dots + x_n}{n}$ .



- *Media geométrica:*  $\mathcal{A}(x_1, \dots, x_n) = (x_1 \cdot \dots \cdot x_n)^{\frac{1}{n}}$ .
- *Máximo:*  $\mathcal{A}(x_1, \dots, x_n) = \max\{x_1, \dots, x_n\}$ .
- *Mínimo:*  $\mathcal{A}(x_1, \dots, x_n) = \min\{x_1, \dots, x_n\}$ .

La siguiente definición recoge algunas de las propiedades de las funciones de agregación que desempeñarán un papel importante en este trabajo.

**Definición 2.5.** [2, 23] Una función de agregación  $\mathcal{A}$  se dice:

- *simétrica* si su resultado no depende de la permutación de los elementos de entrada,
- *idempotente* si  $\mathcal{A}(x, \dots, x) = x$  para todo  $x \in [0, 1]$ ,
- *1-estricta* si  $\mathcal{A}(x_1, \dots, x_n) = 1$  si y solo si  $x_i = 1$  para todo  $i \in \{1, \dots, n\}$ ,
- *0-estricta* si  $\mathcal{A}(x_1, \dots, x_n) = 0$  si y solo si  $x_i = 0$  para todo  $i \in \{1, \dots, n\}$ ,
- *asociativa* si  $\mathcal{A}(x, \mathcal{A}(y, z)) = \mathcal{A}(\mathcal{A}(x, y), z)$  para todo  $x, y, z \in [0, 1]$ . Esta propiedad puede extenderse para un mayor número de elementos de entrada de forma sencilla.

Todas las funciones introducidas en el ejemplo previo son simétricas e idempotentes. En cuanto a la propiedad de ser 1-estricta o 0-estricta, la media aritmética verifica las dos, mientras que la media geométrica y el mínimo solo cumplen la primera y el máximo la segunda. Finalmente, tanto el máximo como el mínimo son asociativas, mientras que ninguna de las medias lo es. Para verlo, se muestra el siguiente ejemplo.

**Ejemplo 2.2.** Considerar  $x_1 = 0.1$ ,  $x_2 = 0.2$  y  $x_3 = 0.3$  y  $\mathcal{A}$  la media aritmética. Se tiene que:

- $\mathcal{A}(\mathcal{A}(x_1, x_2), x_3) = \frac{1}{2}(\frac{x_1+x_2}{2} + x_3) = \frac{1}{2}(\frac{0.1+0.2}{2} + 0.3) = 0.225$ ,
- $\mathcal{A}(x_1, \mathcal{A}(x_2, x_3)) = \frac{1}{2}(x_1 + \frac{x_2+x_3}{2}) = \frac{1}{2}(0.1 + \frac{0.2+0.3}{2}) = 0.175$ .

Al no coincidir ambos resultados, se demuestra que dicha función de agregación no es asociativa.

Si se toma ahora la misma terna de números reales y como función de agregación  $\mathcal{A}$  la media geométrica, se llega a:

- $\mathcal{A}(x_1, \mathcal{A}(x_2, x_3)) = \sqrt{x_1 \cdot \sqrt{x_2 \cdot x_3}} = \sqrt{0.1 \cdot \sqrt{0.2 \cdot 0.3}} = 0.157$ ,
- $\mathcal{A}(\mathcal{A}(x_1, x_2), x_3) = \sqrt{\sqrt{x_1 \cdot x_2} \cdot x_3} = \sqrt{\sqrt{0.1 \cdot 0.2} \cdot 0.3} = 0.206$ .

La media geométrica tampoco verifica la asociatividad.

Una subfamilia de las funciones de agregación que ha sido ampliamente estudiada en la literatura son las normas triangulares. Esta familia de funciones, que viene determinada por las propiedades que se recogen en la siguiente definición, fue introducida originalmente en el contexto de la lógica difusa para extender el operador lógico “y”.

**Definición 2.6.** [15] *Una función  $T : [0, 1]^2 \rightarrow [0, 1]$  es una norma triangular o  $t$ -norma si verifica las siguientes propiedades:*

- T1) Conmutatividad:  $T(x_1, x_2) = T(x_2, x_1)$  para todo  $x_1, x_2 \in [0, 1]$ .*
- T2) Asociatividad:  $T(T(x_1, x_2), x_3) = T(x_1, T(x_2, x_3))$  para todo  $x_1, x_2, x_3 \in [0, 1]$ .*
- T3) Creciente en cada componente: Dados  $x_1, x_2, x_3, x_4 \in [0, 1]$  tales que  $x_1 \leq x_3$  y  $x_2 \leq x_4$ , se tiene que  $T(x_1, x_2) \leq T(x_3, x_4)$ .*
- T4) Elemento neutro:  $T(1, x) = x$  para todo  $x \in [0, 1]$ .*

**Ejemplo 2.3.** *Entre los cuatro ejemplos de funciones de agregación mencionados anteriormente, solo el mínimo verifica la definición de norma triangular. Tal y como se dijo anteriormente, es conmutativa y asociativa, mientras que las propiedades de creciente por componentes y elemento neutro se satisfacen trivialmente por la definición de mínimo.*

*Otro ejemplo de  $t$ -norma sería el producto, es decir,  $T(x_1, x_2) = x_1 \cdot x_2$ . La conmutatividad, la asociatividad y la existencia de elemento neutro se deducen de las propiedades usuales del producto de números reales, mientras que la monotonía creciente por componentes es inmediata en  $[0, 1]$ .*

Uno de los objetivos principales de este trabajo es proporcionar una nueva herramienta para construir medidas de similitud entre intervalos. Para ello, es necesario introducir previamente el concepto de medida de similitud, entendido como una función que permite cuantificar el grado de semejanza entre dos elementos.

En particular, una medida de similitud sobre intervalos asigna a cada par de intervalos un valor perteneciente a  $[0, 1]$ . Cuanto mayor sea dicho valor, mayor será la similitud entre los intervalos considerados, alcanzándose el valor 1 únicamente en el caso en que ambos coincidan. Además, se pide que sea simétrica y se imponen diferentes propiedades de monotonía basadas en la relación de contenido. En la literatura existen múltiples versiones de la definición de medida de similitud entre conjuntos, pero la mayoría de ellas comparten los tres axiomas recogidos en la definición siguiente [14].

**Definición 2.7.** [22] Una aplicación  $S : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  se dice que es una similitud entre intervalos si verifica los siguientes axiomas:

- S1) Simetría: dados  $a, b \in \mathcal{L}([0, 1])$ , se tiene que  $S(a, b) = S(b, a)$ .
- S2) Identidad:  $S(a, b) = 1$  si y solo si  $a = b$ .
- S3) Transitividad: dados  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $a \subseteq b \subseteq c$ , entonces se cumple que  $S(a, c) \leq S(a, b)$  y  $S(a, c) \leq S(b, c)$ .

Un ejemplo ampliamente conocido es la similitud obtenida a partir del índice de Jaccard [13], propuesto inicialmente en el contexto de la botánica.

**Ejemplo 2.4.** Dados dos conjuntos clásicos y finitos  $A$  y  $B$ , el índice de Jaccard se define como sigue:

$$J(A, B) = \frac{\text{card}(A \cap B)}{\text{card}(A \cup B)},$$

donde «card» denota la cardinalidad del conjunto.

Este índice puede extenderse a intervalos mediante la siguiente expresión:

$$J(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ 1 & \text{si } a = b \\ \frac{w(a \cap b)}{w(a \cup b)} & \text{en otro caso} \end{cases}$$

**Ejemplo 2.5.** Se consideran los siguientes intervalos:  $a = [0.3, 0.6]$ ,  $b = [0.1, 0.5]$ ,  $c = [0.2, 0.8]$  y  $d = [0.7, 0.9]$ , representados en la figura 2.1.




Figura 2.1: Representación de los intervalos  $a$ ,  $b$ ,  $c$  y  $d$ .

A continuación, se aplica el índice de Jaccard para comparar el intervalo  $a$  con los tres restantes. Los resultados se plasman en la siguiente tabla:

Tabla 2.1: Resultados del índice de Jaccard aplicado a cada pareja de intervalos.

| $J(a, b)$ | $J(a, c)$ | $J(a, d)$ |
|-----------|-----------|-----------|
| 0.4       | 0.5       | 0         |

*Se tiene así una primera herramienta para medir la similitud entre pares de intervalos, obteniendo valores intermedios entre 0 y 1. Uno de los objetivos de este trabajo será encontrar otras medidas de similitud que mejoren el rendimiento de estas medidas tradicionales en determinados contextos.*

# Capítulo 3

## Medidas de incrustación para intervalos

En este capítulo se introducen las medidas de incrustación para intervalos, que están estrechamente relacionadas con la inclusión clásica definida en 2.2. El propósito es generalizar esta noción binaria de inclusión mediante una medida que proporcione un valor en  $[0, 1]$  y represente en qué grado un intervalo está contenido en otro. Así, en lugar de limitarse a determinar si se da o no la relación de contenido, estas medidas permiten proporcionar una descripción más precisa de dicha relación.

Estas medidas toman el valor 1 únicamente cuando el primer intervalo está contenido en el segundo en el sentido clásico y toman el valor 0 cuando no tienen elementos en común. Además, resulta lógico pensar que dicha función sea creciente en su segundo argumento. Finalmente, se requiere también una propiedad de monotonía relativa a la primera componente.

**Definición 3.1.** [7] Una medida de incrustación en  $\mathcal{L}([0, 1])$  es una aplicación  $E : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  tal que, para cualesquiera  $a, b, c \in \mathcal{L}([0, 1])$ , se verifican las siguientes propiedades:

- E1)  $E(a, b) = 1$  si y solo si  $a \subseteq b$ .
- E2) Si  $a \neq b$  y  $a \cap b = \emptyset$ , entonces  $E(a, b) = 0$ .
- E3) Si  $b \subseteq c$ , entonces  $E(a, b) \leq E(a, c)$ .
- E4) Si  $a \subseteq b \subseteq c$ , entonces  $E(c, a) \leq E(b, a)$ .

Algunas propiedades de estas funciones que se deducen directamente de su definición axiomática se recogen en la siguiente proposición.

**Proposición 3.1.** [7] *Dados  $a, b, c \in \mathcal{L}([0, 1])$ , se cumple que:*

- (I) *Si  $a \cap b \neq \emptyset$ , entonces  $E(a \cap b, a) = E(a \cap b, b) = E(a, a \cup b) = E(b, a \cup b) = 1$ .*
- (II) *Si  $b \cap c \neq \emptyset$ , entonces  $E(a, b \cap c) \leq \min\{E(a, b), E(a, c)\}$ .*

Una vez definidos estos objetos de forma axiomática, el siguiente paso es presentar métodos para construirlos.

### 3.1. Incrustación basada en la amplitud de los intervalos

Una primera forma de definir medidas de incrustación consiste en recurrir a la amplitud de los intervalos involucrados. En particular, se presenta el caso más utilizado, que forma parte de una familia más general basada también en amplitudes.

**Proposición 3.2.** [7] *La aplicación  $E_w : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  definida por:*

$$E_w(a, b) = \begin{cases} 1 & \text{si } w(a) = 0, a \cap b \neq \emptyset \\ 0 & \text{si } w(a) = 0, a \cap b = \emptyset \\ \frac{w(a \cap b)}{w(a)} & \text{si } w(a) \neq 0 \end{cases}$$

*es una incrustación para intervalos.*

*Demostración.* Es claro que  $E_w$  está bien definida pues los valores que toma están en el intervalo  $[0, 1]$ . Para comprobar que es una medida de incrustación, se prueba que verifica los cuatro axiomas de la definición 3.1:

E1) Dados  $a, b \in \mathcal{L}([0, 1])$  tales que  $a \subseteq b$ , se distinguen dos casos:

- Si  $w(a) = 0$ , entonces  $a \cap b = a \neq \emptyset$ , luego  $E_w(a, b) = 1$ .
- Si  $w(a) \neq 0$ ,  $E_w(a, b) = \frac{w(a \cap b)}{w(a)} = \frac{w(a)}{w(a)} = 1$ .

Recíprocamente, supongamos que  $E_w(a, b) = 1$ . Se distinguen dos casos:

- o bien  $w(a) = 0$  y  $a \cap b \neq \emptyset$ . Esto es  $a \subseteq b$ ,
- o bien  $w(a \cap b) = w(a)$ . Equivalentemente,  $a \subseteq b$ .

E2) Sean  $a, b$  tales que  $a \cap b = \emptyset$ . Si  $w(a) = 0$ , entonces  $E_w(a, b) = 0$ . De otra forma,  

$$E_w(a, b) = \frac{w(a \cap b)}{w(a)} = 0.$$

E3) Dados  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $b \subseteq c$ , se distinguen los siguientes casos.

- Si  $w(a) = 0$  y  $a \cap b \neq \emptyset$ , entonces  $a \cap c \neq \emptyset$  y  $E_w(a, b) = 1 = E_w(a, c)$ .
- Si  $w(a) = 0$  y  $a \cap b = \emptyset$ , entonces  $E_w(a, b) = 0$  y la desigualdad se verifica trivialmente.
- Si  $w(a) \neq 0$  y  $a \cap b \neq \emptyset$ , entonces  $E_w(a, b) = \frac{w(a \cap b)}{w(a)} \leq \frac{w(a \cap c)}{w(a)} = E_w(a, c)$ .
- Si  $w(a) \neq 0$  y  $a \cap b = \emptyset$ , la prueba es inmediata.

E4) Sean  $a \subseteq b \subseteq c$ . Hay que probar que  $E_w(c, a) \leq E_w(b, a)$ .

Si  $w(c) = 0$ , entonces necesariamente  $a = b = c$ , y por tanto  $E_w(c, a) = E_w(b, a) = 1$ .

Supongamos ahora que  $w(c) > 0$ . Como  $a \subseteq c$ , se tiene  $c \cap a = a$ , luego  $E_w(c, a) = \frac{w(a)}{w(c)}$ . Si  $w(b) = 0$ , entonces, al cumplirse  $a \subseteq b$ , también  $w(a) = 0$  y  $a = b$ . Por tanto,  $E_w(b, a) = 1$  y  $E_w(c, a) = \frac{w(a)}{w(c)} = 0 \leq 1 = E_w(b, a)$ .

Finalmente, si  $w(b) > 0$ , entonces  $E_w(b, a) = \frac{w(a)}{w(b)}$ . Como  $b \subseteq c$ , se tiene  $w(b) \leq w(c)$ , y por tanto  $\frac{w(a)}{w(c)} \leq \frac{w(a)}{w(b)}$ . Así,  $E_w(c, a) \leq E_w(b, a)$ .

Queda demostrado que la función propuesta es una medida de incrustación. □

**Ejemplo 3.3.** Se consideran los intervalos  $a = [0.2, 0.6]$ ,  $b_1 = [0.4, 0.5]$ ,  $b_2 = [0.7, 0.9]$  y  $b_3 = [0.4, 0.9]$ , representados en la figura 3.1. Es claro que  $b_1$  está contenido completamente en  $a$ ,  $b_2$  no tiene ningún elemento en común con  $a$  y  $b_3$  está parcialmente contenido.

Tomando la incrustación  $E_w$ , los grados de inclusión de los intervalos  $b_i$  con  $i \in \{1, 2, 3\}$  en el intervalo  $a$  son los siguientes:

- $E_w(b_1, a) = \frac{w(b_1 \cap a)}{w(b_1)} = \frac{w(b_1)}{w(b_1)} = 1.$
- $E_w(b_2, a) = \frac{w(b_2 \cap a)}{w(b_2)} = \frac{w(\emptyset)}{w(b_2)} = 0.$
- $E_w(b_3, a) = \frac{w(b_3 \cap a)}{w(b_3)} = \frac{w([0.4, 0.6])}{w(b_3)} = \frac{0.2}{0.5} = 0.4.$

Los resultados obtenidos son coherentes con la idea de incrustación y con cómo estaban relacionados estos intervalos.

Este ejemplo permite ilustrar también que las medidas de incrustación no son necesariamente conmutativas.

- $E_w(a, b_1) = \frac{w(a \cap b_1)}{w(a)} = \frac{w(b_1)}{w(a)} = \frac{0.1}{0.4} = 0.25.$

- $E_w(a, b_2) = \frac{w(a \cap b_2)}{w(a)} = \frac{w(\emptyset)}{w(a)} = 0.$
- $E_w(a, b_3) = \frac{w(a \cap b_3)}{w(a)} = \frac{w([0.4, 0.6])}{w(a)} = \frac{0.2}{0.4} = 0.5.$

Estos valores siguen siendo acordes a lo que se esperaba. Por ejemplo, para el caso  $E_w(a, b_1)$ , un resultado de 0.25 tiene bastante sentido, pues la amplitud de  $a$  es 4 veces la de  $b_1$ , y al estar este completamente contenido en el otro, se podría decir que  $a$  está “contenido una cuarta parte” en  $b_1$ .




Figura 3.1: Representación de los intervalos  $a$ ,  $b_1$ ,  $b_2$  y  $b_3$ .

## 3.2. Incrustaciones basadas en implicaciones

Otra forma de construir medidas de incrustación es mediante funciones de implicación difusas. Este será el método de generación de incrustaciones en el que se hará mayor hincapié a lo largo de este trabajo.

En el contexto de la lógica binaria clásica, una implicación entre dos proposiciones  $A$  y  $B$  no es más que una relación denotada por  $A \rightarrow B$  y que lingüísticamente se interpreta como “si  $A$ , entonces  $B$ ”. Formalmente, se define como  $\neg A \vee B$  (NO  $A$  O  $B$ ), de modo que su tabla de verdad es la siguiente:

Tabla 3.1: Tabla de verdad de  $\neg A \vee B$ .

| $A$ | $B$ | $\neg A$ | $\neg A \vee B$ |
|-----|-----|----------|-----------------|
| 0   | 0   | 1        | 1               |
| 0   | 1   | 1        | 1               |
| 1   | 0   | 0        | 0               |
| 1   | 1   | 0        | 1               |



Al estar en lógica binaria, la implicación solo puede ser cierta (1) o falsa (0). Notamos que únicamente es falsa en el caso de que  $A$  sea verdadera y  $B$  falsa, mientras que en las otras tres situaciones es verdadera.

En el ámbito de la lógica difusa las implicaciones no son booleanas, sino que toman valores en el intervalo  $[0, 1]$ . Así, se entiende que la implicación es “más cierta” cuanto más próximo esté el valor resultante a 1. Concretamente, las implicaciones difusas se definen mediante funciones  $I : [0, 1] \times [0, 1] \longrightarrow [0, 1]$  tales que:

$$(A \rightarrow B)(x, y) := I(A(x), B(y)),$$

donde  $x$  e  $y$  pertenecen a los dominios  $X$  e  $Y$ , respectivamente, y  $A$  y  $B$  son proposiciones difusas sobre dichos dominios, es decir, conjuntos difusos sobre  $X$  e  $Y$ . Los valores  $A(x)$  y  $B(y)$  representan el grado de pertenencia de  $x$  y de  $y$  a los conjuntos difusos correspondientes. Así, un ejemplo de situación que se podría modelizar es la siguiente: “Si el servicio en un restaurante es bueno, la satisfacción de los clientes es alta”. En este caso, expresiones como buen servicio o satisfacción alta no se describen adecuadamente mediante lógica binaria, por lo que son necesarias estas herramientas de la lógica difusa [19, 26]. Axiomáticamente, estas funciones se definen como se muestra a continuación.

**Definición 3.2.** [7] *Una función  $I : [0, 1] \times [0, 1] \longrightarrow [0, 1]$  se dice que es una función de implicación si satisface:*

- I1)  *$I$  es decreciente en la primera componente.*
- I2)  *$I$  es creciente en la segunda componente.*
- I3)  *$I(0, 0) = I(1, 1) = 1$  y  $I(1, 0) = 0$ .*

Además, nos limitaremos a trabajar con funciones de implicación que satisfacen la siguiente propiedad, conocida como propiedad de ordenación:

$$I4) \quad I(x, y) = 1 \iff x \leq y.$$

Otra propiedad que tendrá relevancia en capítulos posteriores es la que se muestra en la definición siguiente.

**Definición 3.3.** [23] *Una función de implicación  $I$  se dice que satisface la propiedad de mínima falsedad si:*

$$I(x, y) = 0 \iff x = 1 \text{ y } y = 0.$$

Con todo esto, el siguiente resultado proporciona un método para obtener incrustaciones a partir de estas funciones:

**Proposición 3.4.** [7] *Dada una función de implicación  $I$ , la aplicación  $E_I : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  definida como:*

$$E_I(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ \min\{I(\underline{b}, \underline{a}), I(\bar{a}, \bar{b})\} & \text{en otro caso} \end{cases}$$

*es una incrustación para intervalos.*

*Demostración.* Nótese que  $E_I$  está bien definida, pues los valores que toma están en  $[0, 1]$ . Veamos si cumple los cuatro axiomas de la definición de medida de incrustación:

E1) Se debe probar que  $E_I(a, b) = 1$  si y solo si  $I(\underline{b}, \underline{a}) = I(\bar{a}, \bar{b}) = 1$ . Usando I4), esto es equivalente a que  $\underline{b} \leq \underline{a}$  y  $\bar{a} \leq \bar{b}$ , es decir,  $a \subseteq b$ .

E2) Si  $a \cap b = \emptyset$ , por definición de  $E_I$ , se tiene que  $E_I(a, b) = E_I(b, a) = 0$ .

E3) Sean  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $b \subseteq c$ . Se distinguen varios casos:

- Si  $a \cap c = \emptyset$  entonces, como  $b \subseteq c$ , también  $a \cap b = \emptyset$ . Por tanto,  $E_I(a, b) = E_I(a, c) = 0$ .
- Si  $a \cap c \neq \emptyset$  y  $a \cap b = \emptyset$ , entonces  $E_I(a, b) = 0$  y la propiedad se cumple trivialmente.
- Si  $a \cap c \neq \emptyset$  y  $a \cap b \neq \emptyset$ . Teniendo en cuenta que  $\underline{c} \leq \underline{b}$  y  $\bar{b} \leq \bar{c}$ , por ser  $I$  decreciente en la primera componente y creciente en la segunda, se tiene que  $I(\underline{b}, \underline{a}) \leq I(\underline{c}, \underline{a})$  y  $I(\bar{a}, \bar{b}) \leq I(\bar{a}, \bar{c})$ , luego  $E_I(a, b) \leq E_I(a, c)$ .

E4) Dados  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $\underline{c} \leq \underline{b} \leq \underline{a} \leq \bar{a} \leq \bar{b} \leq \bar{c}$  ( $a \subseteq b \subseteq c$ ). Como  $I$  es decreciente en la primera componente y creciente en la segunda, se tiene que  $I(\bar{c}, \bar{a}) \leq I(\bar{b}, \bar{a})$  y  $I(\underline{a}, \underline{c}) \leq I(\underline{a}, \underline{b})$ . Así,  $E_I(c, a) \leq E_I(b, a)$ .

□

A continuación se presenta un método de construcción de funciones de implicación que permitirá, más adelante, construir medidas de incrustación a partir de la proposición previa.

**Proposición 3.5.** [7] *Consideramos  $\Delta = \{(x, y) \in [0, 1]^2 | x > y\}$  y sea  $f : \Delta \longrightarrow [0, 1]$  una función que cumple:*

- $f$  es decreciente en su primer argumento.
- $f$  es creciente en su segundo argumento.
- $f(1, 0) = 0$ .

Entonces la función  $I_f : [0, 1]^2 \longrightarrow [0, 1]$  definida como:

$$I_f(x, y) = \begin{cases} 1 & \text{si } x \leq y \\ f(x, y) & \text{en otro caso} \end{cases}$$

es una función de implicación.

*Demostración.* Para demostrarlo, hay que comprobar que cumple los axiomas de la definición 3.2. Por como está definida  $f$ , es claro que los axiomas  $I1)$ ,  $I2)$  e  $I4)$  se verifican. Veamos finalmente si se da  $I3)$ . Tenemos que  $I_f(0, 0) = I_f(1, 1) = 1$  porque  $I_f(x, y) = 1$  si  $x \leq y$ , mientras que  $I_f(1, 0) = f(1, 0) = 0$  por hipótesis.  $\square$

Algunas medidas de incrustación que pueden obtenerse a partir de los dos resultados mostrados previamente son las siguientes:

- **Łukasiewicz:**  $f_{LK}(x, y) = 1 - x + y$ . La incrustación resultante es:

$$E_{LK}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ \min\{1 - \underline{b} + \underline{a}, 1 - \bar{a} + \bar{b}, 1\} & \text{en otro caso} \end{cases} \quad (3.1)$$

En la segunda situación es necesario poner el 1 para evitar excederse. Por ejemplo, si  $a = [0.2, 0.4]$  y  $b = [0.1, 0.8]$ ,  $1 - \underline{b} + \underline{a} = 1.1$  y  $1 - \bar{a} + \bar{b} = 1.1$ , mientras que, por definición de incrustación,  $E(a, b) \in [0, 1]$ . De ahí la necesidad de introducir esa cota.

- **Gödel:**  $f_{GD}(x, y) = y$ . A continuación se calcula la expresión de la incrustación asociada. Dados  $a, b \in \mathcal{L}([0, 1])$ , si  $a \cap b = \emptyset$ , entonces  $E_{GD}(a, b) = 0$ . Si no se da esto,  $E_{GD}(a, b) = \min\{I_{GD}(\underline{b}, \underline{a}), I_{GD}(\bar{a}, \bar{b})\}$ . Se distinguen tres casos: si  $I_{GD}(\underline{b}, \underline{a}) = I_{GD}(\bar{a}, \bar{b}) = 1$ , entonces  $\underline{b} \leq \underline{a}$  y  $\bar{a} \leq \bar{b}$ , luego  $a \subseteq b$ . Si  $\underline{b} \leq \underline{a}$  pero  $\bar{a} > \bar{b}$ , entonces  $E_{GD}(a, b) = I_{GD}(\bar{a}, \bar{b}) = \bar{b}$ , mientras que en el caso  $\underline{a} < \underline{b}$  se tiene

que  $E_{GD}(a, b) = I_{GD}(\underline{b}, \underline{a}) = \underline{a}$ . Así,

$$E_{GD}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ 1 & \text{si } a \subseteq b \\ \bar{b} & \text{si } \underline{b} \leq \underline{a} \leq \bar{b} < \bar{a} \\ \underline{a} & \text{en otro caso} \end{cases} \quad (3.2)$$

- **Goguen:**  $f_{GG}(x, y) = \frac{y}{x}$ . Dados  $a, b \in \mathcal{L}([0, 1])$ , si  $a \cap b = \emptyset$ , entonces  $E_{GG}(a, b) = 0$ . Alternativamente,  $E_{GG}(a, b) = \min\{I_{GG}(\underline{b}, \underline{a}), I_{GG}(\bar{a}, \bar{b})\}$ . Se dan otra vez tres casos: si  $I_{GG}(\underline{b}, \underline{a}) = I_{GG}(\bar{a}, \bar{b}) = 1$ , entonces  $\underline{b} \leq \underline{a}$  y  $\bar{a} \leq \bar{b}$ , luego  $a \subseteq b$ . En otro caso,  $E_{GG}(a, b) = \min\{I_{GG}(\underline{b}, \underline{a}), I_{GG}(\bar{a}, \bar{b})\} = \min\{\frac{a}{b}, \frac{\bar{b}}{\bar{a}}\}$ , salvo que  $\underline{b} = 0$  que entonces  $E_{GG}(a, b) = \frac{\bar{b}}{\bar{a}}$ . Con todo ello, se obtiene la siguiente expresión:

$$E_{GG}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ 1 & \text{si } a \subseteq b \\ \frac{\bar{b}}{\bar{a}} & \text{si } a \cap b \neq \emptyset \text{ y } \underline{b} = 0 \\ \min\{\frac{a}{b}, \frac{\bar{b}}{\bar{a}}\} & \text{en otro caso} \end{cases} \quad (3.3)$$

- **Fodor:**  $f_{FD}(x, y) = \max(1 - x, y)$ . Siguiendo un proceso similar a los casos anteriores, la incrustación correspondiente es:

$$E_{FD}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ 1 & \text{si } a \subseteq b \\ \max\{1 - \bar{a}, \bar{b}\} & \text{si } \underline{b} \leq \underline{a} \leq \bar{b} < \bar{a} \\ \max\{1 - \underline{b}, \underline{a}\} & \text{si } \underline{a} < \underline{b} \leq \bar{a} \leq \bar{b} \\ \min(\max\{1 - \bar{a}, \bar{b}\}, \max\{1 - \underline{b}, \underline{a}\}) & \text{en otro caso} \end{cases} \quad (3.4)$$

Debido a que el criterio para construir estas implicaciones es bastante general, existen multitud de ejemplos adicionales. En este trabajo se propone uno nuevo, que se desarrolla a continuación.

**Proposición 3.6.** *La función*

$$I_{EXP}(x, y) = \begin{cases} 1 & \text{si } x \leq y \\ y e^{1-x} & \text{en otro caso} \end{cases}$$

es una función de implicación, a la que se conocerá con el nombre de **implicación exponencial**

*Demostración.* Sea  $\Delta$  el conjunto definido en la proposición 3.5. Se considera una función definida de la siguiente manera:

$$f : \Delta \longrightarrow [0, 1)$$

$$f(x, y) = y e^{1-x}.$$

Es directo comprobar que  $f$  es decreciente en su primer argumento, creciente en el segundo y  $f(1, 0) = 0$ , luego gracias a la proposición 3.5 se obtiene que  $I_{EXP}$  es una función de implicación, tal y como se quería demostrar.  $\square$

Se obtiene así una medida de incrustación a partir de esa implicación.

**Proposición 3.7.** *Dada la función de implicación  $I_{EXP}$  definida en la proposición 3.6, se tiene que la función*

$$E_{EXP}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ \min\{I_{EXP}(\underline{b}, \underline{a}), I_{EXP}(\bar{a}, \bar{b})\} & \text{en otro caso} \end{cases}$$

*es una medida de incrustación para intervalos, que recibe el nombre de **incrustación exponencial***

*Demostración.* Es consecuencia directa de aplicar la proposición 3.4. Separando por casos, la forma completa de la incrustación queda de la siguiente manera:

$$E_{EXP}(a, b) = \begin{cases} 0 & \text{si } a \cap b = \emptyset \\ 1 & \text{si } a \subseteq b \\ \bar{b} e^{1-\bar{a}} & \text{si } \underline{b} \leq \underline{a} \leq \bar{b} < \bar{a} \\ \underline{a} e^{1-\underline{b}} & \text{si } \underline{a} < \underline{b} \leq \bar{a} \leq \bar{b} \\ \min\{\bar{b} e^{1-\bar{a}}, \underline{a} e^{1-\underline{b}}\} & \text{en otro caso} \end{cases} \quad (3.5)$$

$\square$

**Ejemplo 3.8.** *Se consideran de nuevo los intervalos  $a$ ,  $b_1$ ,  $b_2$  y  $b_3$ , utilizados en el ejemplo 3.3 y, por tanto, representados en la figura 3.1. De manera análoga a dicha*

situación, se calcula el valor de la incrustación exponencial para las mismas parejas de intervalos. Los resultados son los siguientes:

Tabla 3.2: Resultados de la incrustación exponencial aplicada a cada par de intervalos.

| $E_{EXP}(b_1, a)$ | $E_{EXP}(b_2, a)$ | $E_{EXP}(b_3, a)$ | $E_{EXP}(a, b_1)$ | $E_{EXP}(a, b_2)$ | $E_{EXP}(a, b_3)$ |
|-------------------|-------------------|-------------------|-------------------|-------------------|-------------------|
| 1                 | 0                 | 0.6631            | 0.3644            | 0                 | 0.3644            |

Comparando con los valores obtenidos para la otra incrustación, se aprecia cómo en los casos límite, es decir, cuando un intervalo está contenido en el otro o bien son disjuntos, ambas medidas coinciden. Para los casos intermedios, a pesar de que los resultados no son muy dispares, sí son distintos. Esto se debe fundamentalmente a que su naturaleza es completamente distinta, pues  $E_w$  se basa en la amplitud, mientras que  $E_{EXP}$  trabaja con los valores de los extremos.

Por otra parte, entre las implicaciones anteriores, las de Łukasiewicz y Fodor verifican la propiedad de mínima falsedad, lo que conducirá a que las incrustaciones asociadas solo den valores nulos en situaciones muy concretas (ver corolario 4.23).

Una propiedad interesante de este tipo de incrustaciones es que es posible establecer un orden entre ellas de la siguiente manera:

**Corolario 3.9.** [7] Sean dos funciones  $f_1$  y  $f_2$  verificando las condiciones de la proposición 3.5 y  $f_1 \leq f_2$ , es decir,  $f_1(x, y) \leq f_2(x, y)$  para todo par  $(x, y) \in \Delta$ . Entonces, se cumple que  $I_{f_1} \leq I_{f_2}$  y  $E_{I_{f_1}} \leq E_{I_{f_2}}$ .

*Demostración.* Por como se definen las funciones de implicación  $I_{f_1}$  y  $I_{f_2}$ , es claro que  $I_{f_1} \leq I_{f_2}$ . En cuanto a las incrustaciones, dados  $a, b \in \mathcal{L}([0, 1])$ , se tiene que si  $a \cap b = \emptyset$ , entonces  $E_{I_{f_1}}(a, b) = 0 = E_{I_{f_2}}(a, b)$ . Si por el contrario  $a \cap b \neq \emptyset$ , se llega a  $I_{f_1}(\underline{b}, \underline{a}) \leq I_{f_2}(\underline{b}, \underline{a})$  y  $I_{f_1}(\bar{a}, \bar{b}) \leq I_{f_2}(\bar{a}, \bar{b})$ , concluyendo que  $E_{I_{f_1}}(a, b) \leq E_{I_{f_2}}(a, b)$  por como están definidas estas incrustaciones.  $\square$

Las medidas de incrustación mencionadas presentan la relación de orden que se observa en la figura 3.2. Además, no se puede establecer ninguna relación entre las incrustaciones de Fodor y Goguen/Exponencial, tal y como refleja el siguiente contraejemplo:

- $E_{GG}([0.1, 0.4], [0.2, 0.5]) = 0.5$ ,  $E_{EXP}([0.1, 0.4], [0.2, 0.5]) = 0.22$  y  $E_{FD}([0.1, 0.4], [0.2, 0.5]) = 0.8$ .
- $E_{GG}([0.1, 0.6], [0, 0.5]) = 0.83$ ,  $E_{EXP}([0.1, 0.6], [0, 0.5]) = 0.75$  y  $E_{FD}([0.1, 0.6], [0, 0.5]) = 0.5$ .




Figura 3.2: Relaciones de orden entre las diferentes incrustaciones.

Esta relación de orden queda reflejada en el siguiente ejemplo.

**Ejemplo 3.10.** Sea la familia de intervalos  $a_\varepsilon = [\varepsilon, \varepsilon + 0.1]$ , donde  $\varepsilon = 0, 0.1, \dots, 0.9$ . Vamos a medir el grado de incrustación de estos intervalos en los dos siguientes:  $b_1 = [0.35, 0.55]$  y  $b_2 = [0.4, 0.7]$ . Para ello, se usan las cinco incrustaciones construidas mediante funciones de implicación. Los resultados aparecen representados en la figura 3.3.




Figura 3.3: Resultados de las incrustaciones para los distintos valores de  $a_\varepsilon$  y  $b_1, b_2$ .

## Capítulo 4

# Similitudes basadas en medidas de incrustación

Una vez presentadas las medidas de incrustación, en este capítulo se tratará de ligarlas con las medidas de similitud, previamente introducidas en el capítulo 2.

Como su propio nombre indica, las similitudes son objetos cuyo principal objetivo es establecer cómo de parecidos son dos elementos de un conjunto. En un contexto clásico, la comparación entre dos objetos suele reducirse a una distinción binaria: coinciden o no coinciden. En el contexto de los intervalos, que dos intervalos sean iguales se define como que uno esté contenido en el otro y viceversa, mientras que de lo contrario se dice que son diferentes. Las medidas de incrustación ofrecen una forma de cuantificar el grado de inclusión de un intervalo en otro, generalizando dicha relación e incluyendo los casos clásicos. Así, lo que se necesita es simplemente una forma de combinar los grados de incrustación, de manera que se obtenga una aplicación que verifique los axiomas de similitud. Para ello, se propone recurrir a funciones de agregación simétricas y 1-estrictas.

**Proposición 4.1.** [6] *Sea  $E$  una incrustación para intervalos y  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Entonces, la función  $S_{\mathcal{A}}^E : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \rightarrow [0, 1]$  dada por:*

$$S_{\mathcal{A}}^E(a, b) = \mathcal{A}(E(a, b), E(b, a))$$

*es una similitud para intervalos.*



*Demostración.* Para ver que esa aplicación es una similitud, es necesario comprobar los axiomas de la definición 2.7:

S1) Simetría: es directo que dicha aplicación es simétrica.

S2) Identidad: sean  $a, b \in \mathcal{L}([0, 1])$ . Supongamos primero que  $S_{\mathcal{A}}^E(a, b) = 1$ . Como  $\mathcal{A}$  es 1-estricta, se tiene que  $E(a, b) = E(b, a) = 1$ , y por el primer axioma de la definición de medida de incrustación, se verifica que  $a \subseteq b$  y  $b \subseteq a$ . Equivalentemente,  $a = b$ .

Nótese que si  $a = b$ , se cumple que  $E(a, b) = E(b, a) = 1$  y, por las condiciones de frontera de las funciones de agregación, se tiene la igualdad buscada:  $S_{\mathcal{A}}^E(a, b) = \mathcal{A}(1, 1) = 1$ .

S3) Transitividad: dados  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $a \subseteq b \subseteq c$ , entonces por el primer axioma de incrustación se tiene que  $E(a, b) = E(a, c) = E(b, c) = 1$ . Además, por el tercer y cuarto axioma de esa misma definición, obtenemos que  $E(c, a) \leq E(b, a)$  y  $E(c, a) \leq E(c, b)$ . Del crecimiento de las funciones de agregación, se deduce:

$$\begin{aligned} S_{\mathcal{A}}^E(a, c) &= \mathcal{A}(1, E(c, a)) \leq \mathcal{A}(1, E(b, a)) = S_{\mathcal{A}}^E(a, b), \\ S_{\mathcal{A}}^E(a, c) &= \mathcal{A}(1, E(c, a)) \leq \mathcal{A}(1, E(c, b)) = S_{\mathcal{A}}^E(b, c). \end{aligned}$$

□

Como toda t-norma es, en particular, una función de agregación simétrica y 1-estricta, se obtiene directamente el siguiente resultado.

**Corolario 4.2.** *Sea  $E$  una incrustación para intervalos y  $T$  una t-norma. Entonces, la función  $S_T^E : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  dada por:*

$$S_T^E(a, b) = T(E(a, b), E(b, a))$$

*es una similitud para intervalos.*

*Demostración.* Se deduce directamente de la proposición 4.1. □

Con todo el desarrollo teórico llevado a cabo en el capítulo anterior y al principio de este, se disponen de herramientas suficientes para construir múltiples similitudes. Basta seleccionar una de las varias incrustaciones expuestas en secciones anteriores y una t-norma o función de agregación simétrica y 1-estricta. A continuación se pone a prueba esta construcción con el siguiente ejemplo:

**Ejemplo 4.3.** Se consideran los intervalos definidos en el ejemplo 2.5 y, por tanto, representados en la figura 2.1. Al igual que en ese caso, se compara el intervalo  $a$  con los tres restantes. Sin embargo, las similitudes utilizadas se construirán a partir de dos incrustaciones: la basada en la amplitud de los intervalos presentada en la proposición 3.2 y la basada en la implicación de Łukasiewicz (3.1). Las funciones de agregación empleadas son el mínimo (es una  $t$ -norma) y la media aritmética (es simétrica y 1-estricta). Los resultados obtenidos pueden verse en la tabla 4.1:

Tabla 4.1: Valores de las medidas de similitud por par de intervalos.

| Par de intervalos | $S_{med}^{E_w}$ | $S_{\min}^{E_w}$ | $S_{med}^{E_{LK}}$ | $S_{\min}^{E_{LK}}$ |
|-------------------|-----------------|------------------|--------------------|---------------------|
| (a, b)            | 0.58            | 0.50             | 0.85               | 0.80                |
| (a, c)            | 0.75            | 0.50             | 0.90               | 0.80                |
| (a, d)            | 0.00            | 0.00             | 0.00               | 0.00                |

Gráficamente, los resultados se ven en la figura 4.1:




Figura 4.1: Valores de las cuatro similitudes para cada pareja de intervalos.

De este ejemplo se extrae que todas coinciden en el caso en el que la intersección entre intervalos es vacía, lo que es lógico, pues están construidas a partir de operadores de incrustación, e intersección vacía implica que el grado en el que un intervalo está incrustado en otro es nulo.

## 4.1. $\sqcup$ —Similitudes basadas en medidas de incrustación

Las funciones de similitud estudiadas hasta el momento constituyen ya de por sí una gran herramienta a la hora de cuantificar la semejanza entre parejas de intervalos. Ahora bien, tal y como veremos a continuación, presentan una limitación, que además es compartida con otros operadores ampliamente empleados en el contexto de la lógica difusa, como son la medida de Jaccard [13] o el índice de Dice [10]. La limitación aparece al considerar intervalos con intersección vacía, ya que en ese caso no distinguen entre intervalos cercanos e intervalos muy alejados.

Considerar primero dos intervalos  $a, b \in \mathcal{L}([0, 1])$  con  $a \cap b = \emptyset$ . Por las propiedades que caracterizan las incrustaciones se tiene que  $E(a, b) = E(b, a) = 0$ . Por otro lado, las condiciones de frontera de las funciones de agregación (incluyendo a las t-normas) implican  $\mathcal{A}(0, 0) = 0$  (2.4). Así, se llega a lo siguiente: toda similitud basada en incrustaciones da como resultado 0 al aplicarla a cualquier par de intervalos con intersección vacía. Lo mismo ocurre con los índices de Jaccard y Dice mencionados anteriormente.

Ahora bien, ¿por qué sería esto una limitación? Podría ser lógico pensar que dos intervalos, si tienen intersección vacía, son muy distintos, luego no sería descabellado que la similitud diese un valor nulo. Sin embargo, el siguiente ejemplo muestra por qué sería adecuado que no siempre fuese así.

**Ejemplo 4.4.** *Se toman los intervalos  $a = [0, 0.09]$ ,  $b = [0.1, 0.2]$  y  $c = [0.9, 1]$ . Es claro que  $a \cap b = a \cap c = \emptyset$ , luego se tiene que  $S_T^E(a, b) = S_T^E(a, c) = 0$  para cualquier incrustación  $E$  y t-norma  $T$ . Es decir, según estas similitudes, la diferencia entre  $a, b$  y  $a, c$  es la misma, la máxima posible. Sin embargo, parecería razonable pensar que estos operadores nos dieran un valor mayor para  $a$  y  $b$  que para  $b$  y  $c$ , pues a priori  $[0, 0.09]$  es más parecido a  $[0.1, 0.2]$  que a  $[0.9, 1]$ .*

Adicionalmente, con dicha construcción de las similitudes, también aparecen dificultades cuando los intervalos son degenerados, pues se da o que ambos coinciden o que son disjuntos, lo que implica que la similitud ofrezca únicamente 0 o 1. En definitiva, estas similitudes no son capaces de captar la proximidad entre intervalos cuando no se solapan.

Así, el objetivo de esta sección será, partiendo del desarrollo anterior, buscar extensiones o modificaciones de las similitudes que trabajen adecuadamente en esas situaciones.

Para ello, se comienza definiendo la siguiente operación en  $\mathcal{L}([0, 1])$ .

**Definición 4.1.** *Dados dos intervalos  $a, b \in \mathcal{L}([0, 1])$ , se define la operación  $a \sqcup b$  como el menor intervalo en  $\mathcal{L}([0, 1])$  que contiene a ambos:*

$$a \sqcup b = [\min\{\underline{a}, \underline{b}\}, \max\{\bar{a}, \bar{b}\}].$$

Este concepto se conoce como envolvente convexa y, aunque este trabajo se centre en el caso de los intervalos cerrados, se puede definir en conjuntos mucho más generales [16]. Además, coincide con la unión clásica si los intervalos no son disjuntos. Sin embargo, si la intersección es vacía, difiere de la unión en el sentido de que puede incluir puntos que no pertenecen a ninguno de los intervalos.

**Ejemplo 4.5.** *Dados  $a_1 = [0.4, 0.5]$  y  $a_2 = [0.6, 0.9]$ , se tiene que  $a_1 \sqcup a_2 = [0.4, 0.9]$ , que incluye a 0.55 a pesar de que éste no pertenece a  $a_1$  ni a  $a_2$ .*

Algunas propiedades de esta operación son las siguientes:

**Lema 4.6.** *Dados  $a, b \in \mathcal{L}([0, 1])$ , se cumple que:*

- $w(a \sqcup b) > w(a) + w(b) \iff a \cap b = \emptyset$ .
- $w(a \sqcup b) = w(a) + w(b) \iff a \cap b$  es un intervalo degenerado.
- $w(a \sqcup b) < w(a) + w(b) \iff a \cap b$  es un intervalo no degenerado.

*Demostración.* Suponer sin pérdida de generalidad que  $\underline{a} \leq \underline{b}$  y  $\bar{a} \leq \bar{b}$ , pues de lo contrario  $a \sqcup b = a$  o  $a \sqcup b = b$  y ya estaría demostrado. Así, se tiene que  $w(a \sqcup b) = \bar{b} - \underline{a}$ . Se distinguen los siguientes casos:

- Si  $a \cap b = \emptyset$ , entonces  $\underline{a} \leq \bar{a} < \underline{b} \leq \bar{b}$ , luego  $w(a \sqcup b) = \bar{b} - \underline{a} = \bar{b} - \underline{b} + \underline{b} - \underline{a} > \bar{b} - \underline{b} + \bar{a} - \underline{a} = w(a) + w(b)$ .
- Si  $a \cap b$  es un intervalo degenerado, se tiene que  $\underline{a} \leq \bar{a} = \underline{b} \leq \bar{b}$ , luego  $w(a \sqcup b) = \bar{b} - \underline{a} = \bar{b} - \underline{b} + \underline{b} - \underline{a} = \bar{b} - \underline{b} + \bar{a} - \underline{a} = w(a) + w(b)$ .
- Si  $a \cap b$  es un intervalo no degenerado, necesariamente  $\underline{a} \leq \underline{b} < \bar{a} \leq \bar{b}$ , luego  $w(a \sqcup b) = \bar{b} - \underline{a} = \bar{b} - \underline{b} + \underline{b} - \underline{a} < \bar{b} - \underline{b} + \bar{a} - \underline{a} = w(a) + w(b)$ .

□

Recurriendo a este operador, se construyen las  $\sqcup$ -similitudes basadas en medidas de incrustación, que permiten distinguir grados de similitud entre pares de intervalos disjuntos.

**Proposición 4.7.** *Sea  $E$  una incrustación para intervalos y  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Entonces, la función  $S_{\mathcal{A}-\sqcup}^E : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \rightarrow [0, 1]$  dada por:*

$$S_{\mathcal{A}-\sqcup}^E(a, b) = \mathcal{A}(E(a \sqcup b, a), E(a \sqcup b, b))$$

*es una similitud para intervalos.*

*Demostración.* Para probarlo, es necesario verificar los axiomas de similitud de la definición 2.7:

- S1) Simetría: se deduce de la simetría del operador de agregación considerado.
- S2) Identidad: sean  $a, b \in \mathcal{L}([0, 1])$ . Supongamos primero que  $S_{\mathcal{A}-\sqcup}^E(a, b) = 1$ . Entonces, como  $\mathcal{A}$  es una función 1-estricta se tiene que  $E(a \sqcup b, b) = E(a \sqcup b, a) = 1$ . Por el primer axioma de la definición de medida de incrustación,  $a \sqcup b \subseteq b$  y  $a \sqcup b \subseteq a$ . Como  $a \sqcup b$  es el menor intervalo que contiene a  $a$  y  $b$ , y a su vez está contenido en ambos, se concluye que  $a = b = a \sqcup b$ .  
La implicación contraria se deduce del primer axioma de la definición de medida de incrustación y de las condiciones de frontera de las funciones de agregación, ya que  $\mathcal{A}(1, 1) = 1$ .
- S3) Transitividad: sean  $a, b, c \in \mathcal{L}([0, 1])$  tales que  $a \subseteq b \subseteq c$ . Por el primer axioma de incrustación se tiene que  $E(a, b) = E(a, c) = E(b, c) = 1$ . Además, por el tercer y cuarto axioma de esa misma definición, obtenemos que  $E(c, a) \leq E(b, a)$  y  $E(c, a) \leq E(c, b)$ .

Por otro lado, es claro también que  $a \sqcup b = b$ ,  $a \sqcup c = c$ ,  $b \sqcup c = c$ . Combinando todas estas ideas con la monotonía creciente por componentes, obtenemos:

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^E(a, c) &= \mathcal{A}(E(a \sqcup c, a), E(a \sqcup c, c)) = \mathcal{A}(E(c, a), E(c, c)) = \mathcal{A}(E(c, a), 1) \\ &\leq \mathcal{A}(E(b, a), 1) = \mathcal{A}(E(b, a), E(b, c)) = \mathcal{A}(E(a \sqcup b, a), E(a \sqcup b, b)) = S_{\mathcal{A}-\sqcup}^E(a, b), \end{aligned}$$

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^E(a, c) &= \mathcal{A}(E(a \sqcup c, a), E(a \sqcup c, c)) = \mathcal{A}(E(c, a), E(c, c)) = \mathcal{A}(E(c, a), 1) \\ &\leq \mathcal{A}(E(c, b), 1) = \mathcal{A}(E(c, b), E(c, c)) = \mathcal{A}(E(b \sqcup c, b), E(b \sqcup c, c)) = S_{\mathcal{A}-\sqcup}^E(b, c). \end{aligned}$$

□

Por ser las  $t$ -normas operadores simétricos y 1-estrictos, puede plantearse el siguiente resultado.

**Corolario 4.8.** *Sea  $E$  una incrustación para intervalos y  $T$  una  $t$ -norma. Entonces, la función  $S_{T-\sqcup}^E : \mathcal{L}([0, 1]) \times \mathcal{L}([0, 1]) \longrightarrow [0, 1]$  dada por:*

$$S_{T-\sqcup}^E(a, b) = T(E(a \sqcup b, a), E(a \sqcup b, b))$$

*es una similitud para intervalos.*

*Demostración.* La demostración se deduce directamente de la proposición 4.7. □

**Ejemplo 4.9.** *Considerar dos tipos de incrustaciones: la basada en la amplitud de los intervalos y la exponencial, definidas en las proposiciones 3.2 y 3.7 respectivamente. Como función de agregación simétrica y 1-estricta, se escoge la media aritmética. Se toman las siguientes parejas de intervalos:*

- $a_1 = [0.2, 0.5], a_2 = [0.3, 0.8],$
- $b_1 = [0.4, 0.6], b_2 = [0.1, 0.3],$
- $c_1 = [0, 0.7], c_2 = [0.9, 1],$
- $d_1 = [0.4, 0.5], d_2 = [0.2, 0.7].$

*En el primer caso los intervalos tienen intersección no vacía, los dos siguientes pares son disjuntos y finalmente en la última pareja  $d_1 \subseteq d_2$ . Se aplican a continuación los dos tipos de similitudes, tanto la desarrollada en la sección anterior como la nueva propuesta basada en la envolvente convexa  $\sqcup$ . Los resultados son los siguientes:*

Tabla 4.2: Resultados de las similitudes aplicadas a cada par de intervalos.

| Par de intervalos | $S_{\mathcal{A}}^{E_w}$ | $S_{\mathcal{A}-\sqcup}^{E_w}$ | $S_{\mathcal{A}}^{EXP}$ | $S_{\mathcal{A}-\sqcup}^{EXP}$ |
|-------------------|-------------------------|--------------------------------|-------------------------|--------------------------------|
| $(a_1, a_2)$      | 0.5333                  | 0.6667                         | 0.3674                  | 0.3674                         |
| $(b_1, b_2)$      | 0                       | 0.4                            | 0                       | 0.3149                         |
| $(c_1, c_2)$      | 0                       | 0.4                            | 0                       | 0.35                           |
| $(d_1, d_2)$      | 0.6                     | 0.6                            | 0.6822                  | 0.6822                         |

*Se observa que, en los casos de intervalos disjuntos, se obtienen valores no nulos para la similitud agregada, justo lo que se buscaba. En cuanto a los otros dos casos,*

existen situaciones en las que ambas similitudes coinciden y otras en las que no. Este asunto se discutirá a continuación.

En el ejemplo anterior se obtuvo que cuando los intervalos se solapaban, ambas similitudes daban el mismo valor. En general, que dicho valor coincida solo se puede garantizar en el caso concreto en el que uno de los intervalos está incluido en el otro, tal y como muestra el siguiente resultado.

**Proposición 4.10.** *Dada una incrustación  $E$ , una función de agregación simétrica y 1-estricta  $\mathcal{A}$  y dos intervalos  $a, b \in \mathcal{L}([0, 1])$  tales que  $a \subseteq b$ , se tiene que  $S_{\mathcal{A}}^E(a, b) = S_{\mathcal{A}-\sqcup}^E(a, b)$ .*

*Demostración.* Notamos que si  $a \subseteq b$ , entonces  $a \sqcup b = b$  y  $E(a, b) = 1$ . Así:

$$S_{\mathcal{A}-\sqcup}^E(a, b) = \mathcal{A}(E(a \sqcup b, a), E(a \sqcup b, b)) = \mathcal{A}(E(b, a), E(b, b)) = \mathcal{A}(E(b, a), 1),$$

$$S_{\mathcal{A}}^E(a, b) = \mathcal{A}(E(a, b), E(b, a)) = \mathcal{A}(1, E(b, a)).$$

Como  $\mathcal{A}$  es simétrica, se tiene  $S_{\mathcal{A}-\sqcup}^E(a, b) = S_{\mathcal{A}}^E(a, b)$ . □

Ahora bien, imponiendo que la incrustación se construya a partir de una implicación, se consigue que ambos operadores den el mismo resultado si la intersección es no vacía.

**Proposición 4.11.** *Dada una incrustación  $E_I$  construida a partir de una función de implicación  $I$ , una función de agregación simétrica y 1-estricta  $\mathcal{A}$  y dos intervalos  $a, b \in \mathcal{L}([0, 1])$  tales que  $a \cap b \neq \emptyset$ , se tiene que  $S_{\mathcal{A}}^{E_I}(a, b) = S_{\mathcal{A}-\sqcup}^{E_I}(a, b)$ .*

*Demostración.* Supongamos sin pérdida de generalidad que  $\bar{a} \leq \bar{b}$ . En ese caso, dado que  $a \cap b \neq \emptyset$ , necesariamente se tiene que  $\underline{b} \leq \bar{a}$ .

Nótese que el caso  $a \subseteq b$  queda probado en la proposición anterior. Por tanto, basta estudiar el caso  $a \preceq_{Lo} b$ , en el que se cumple que  $a \sqcup b = [\underline{a}, \bar{b}]$ . Para obtener el valor de las similitudes se calculan las siguientes incrustaciones:

$$E_I(a, b) = \min\{I(\underline{b}, \underline{a}), I(\bar{a}, \bar{b})\} = I(\underline{b}, \underline{a}),$$

$$E_I(b, a) = \min\{I(\underline{a}, \underline{b}), I(\bar{b}, \bar{a})\} = I(\bar{b}, \bar{a}),$$

$$E_I(a \sqcup b, a) = \min\{I(\underline{a}, \underline{a \sqcup b}), I(\overline{a \sqcup b}, \bar{a})\} = \min\{I(\underline{a}, \underline{a}), I(\bar{b}, \bar{a})\} = I(\bar{b}, \bar{a}),$$

$$E_I(a \sqcup b, b) = \min\{I(\underline{b}, \underline{a \sqcup b}), I(\overline{a \sqcup b}, \bar{b})\} = \min\{I(\underline{b}, \underline{a}), I(\bar{b}, \bar{b})\} = I(\underline{b}, \underline{a}),$$

donde se usó la propiedad de ordenación de las implicaciones (3.2). Con todo esto se llega a:

$$\begin{aligned} S_{\mathcal{A}}^{E_I}(a, b) &= \mathcal{A}(E_I(a, b), E_I(b, a)) = \mathcal{A}(I(\underline{b}, \underline{a}), I(\bar{b}, \bar{a})), \\ S_{\mathcal{A}-\sqcup}^{E_I}(a, b) &= \mathcal{A}(E_I(a \sqcup b, a), E_I(a \sqcup b, b)) = \mathcal{A}(I(\bar{b}, \bar{a}), I(\underline{b}, \underline{a})). \end{aligned}$$

Ambos resultados coinciden debido a que la función de agregación es simétrica, luego la proposición queda demostrada.  $\square$

**Nota 4.12.** *Dicha proposición no se verifica para la incrustación  $E_w$ . Como contraejemplo, basta tomar el primer par de intervalos del ejemplo 4.9.*

La principal motivación de esta sección era extender las similitudes de forma que tuviesen en cuenta la distancia entre intervalos cuando estos no se solapaban. Los siguientes resultados nos van a demostrar cómo, para la incrustación  $E_w$  basada en la amplitud de los intervalos (proposición 3.2), esta modificación cumple su objetivo.

Para comenzar, se demuestra que, si la amplitud de los intervalos no varía, el valor de esta nueva similitud crece a medida que estos están más próximos:

**Proposición 4.13.** *Se considera la incrustación  $E_w$  y función de agregación simétrica y 1-estricta  $\mathcal{A}$ . Sean  $a_1, a_2, b_1, b_2 \in \mathcal{L}([0, 1])$  tales que verifican una de las siguientes condiciones:*

- $w(a_1) = w(a_2)$  y  $w(b_1) = w(b_2)$ ,
- $w(a_1) = w(b_2)$  y  $w(b_1) = w(a_2)$ .

*Entonces, si  $w(a_1 \sqcup b_1) \geq w(a_2 \sqcup b_2)$ , se verifica  $S_{\mathcal{A}-\sqcup}^{E_w}(a_1, b_1) \leq S_{\mathcal{A}-\sqcup}^{E_w}(a_2, b_2)$ .*

*Demostración.* Se comienza con el caso en el que  $w(a_2 \sqcup b_2) = 0$ . Entonces, se tiene que  $a_2 = b_2$  siendo ambos intervalos degenerados. Esto implica que  $S_{\mathcal{A}-\sqcup}^{E_w}(a_2, b_2) = 1$ , luego la desigualdad se cumple trivialmente.

Considerar ahora que  $w(a_2 \sqcup b_2) > 0$ , luego también se da  $w(a_1 \sqcup b_1) > 0$ . Se supone sin pérdida de generalidad que  $w(a_1) = w(a_2)$  y  $w(b_1) = w(b_2)$  (el otro caso es completamente análogo por la simetría de  $\mathcal{A}$ ). Se tiene así que:

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^{E_w}(a_1, b_1) &= \mathcal{A}(E(a_1 \sqcup b_1, a_1), E(a_1 \sqcup b_1, b_1)) = \mathcal{A}\left(\frac{w(a_1)}{w(a_1 \sqcup b_1)}, \frac{w(b_1)}{w(a_1 \sqcup b_1)}\right) \\ &= \mathcal{A}\left(\frac{w(a_2)}{w(a_1 \sqcup b_1)}, \frac{w(b_2)}{w(a_1 \sqcup b_1)}\right) \leq \mathcal{A}\left(\frac{w(a_2)}{w(a_2 \sqcup b_2)}, \frac{w(b_2)}{w(a_2 \sqcup b_2)}\right) \\ &= \mathcal{A}(E(a_2 \sqcup b_2, a_2), E(a_2 \sqcup b_2, b_2)) = S_{\mathcal{A}-\sqcup}^{E_w}(a_2, b_2). \end{aligned}$$



□

**Nota 4.14.** La desigualdad estricta se consigue si se supone  $w(a_1 \sqcup b_1) > w(a_2 \sqcup b_2)$  y:

- $\mathcal{A}$  es conjuntamente estrictamente creciente y los cuatro intervalos son no degenerados.
- $\mathcal{A}$  es estrictamente creciente por componentes y al menos un intervalo de cada par es no degenerado.

El siguiente ejemplo refleja este resultado.

**Ejemplo 4.15.** Sean la incrustación  $E_w$  y la media aritmética (función de agregación simétrica y 1-estricta). Por la nota anterior, al ser ésta estrictamente creciente por componentes, tomando al menos un intervalo no degenerado por cada par, se debería observar la desigualdad estricta. Se consideran las familias de intervalos  $a_\delta = [\delta, \delta + 0.05]$  y  $b_\delta = [1 - \delta, 0.95 - \delta]$ , con  $\delta \in [0, 0.4]$ . Notar que, para cada valor de  $\delta$ , los intervalos  $a$  y  $b$  tienen la misma amplitud y son disjuntos. Ahora bien, lo que sí cambia es la distancia entre los intervalos, pues a medida que aumenta  $\delta$ ,  $a$  y  $b$  están más próximos. Si se calcula el valor de  $S_{\mathcal{A}-\sqcup}^{E_w}$  para diversos  $\delta$ , se obtiene:




Figura 4.2: Valores de  $S_{\mathcal{A}-\sqcup}^{E_w}$  para cada par de intervalos  $a_\delta, b_\delta$ .

Es claro como a medida que estos intervalos se van aproximando, el valor de la similitud aumenta, a pesar de que estos sigan siendo disjuntos. Esto no ocurriría con aquellas definidas en primera instancia, que hubiesen otorgado un valor 0 a todos los casos.

Otra situación que solventa particularmente bien esta similitud concreta es aquella en la que se tienen pares de intervalos disjuntos, cuya envolvente convexa es siempre la misma, pero sus extremos van estando cada vez más próximos. Las primeras similitudes darían como resultado 0 siempre (debido a la intersección vacía), pero parece lógico que a medida que los intervalos son más cercanos, el operador ofrezca un valor mayor. La siguiente proposición garantiza esto último:

**Proposición 4.16.** *Consideramos la incrustación  $E_w$  y una función de agregación simétrica y 1-estricta  $\mathcal{A}$ . Sean  $a_1, b_1, a_2, b_2 \in \mathcal{L}([0, 1])$  tales que se cumplen una de estas dos condiciones:*

- $w(a_1) \geq w(a_2)$  y  $w(b_1) \geq w(b_2)$ ,
- $w(a_1) \geq w(b_2)$  y  $w(b_1) \geq w(a_2)$ .

*Entonces, si  $w(a_1 \sqcup b_1) = w(a_2 \sqcup b_2)$ , se da  $S_{\mathcal{A}-\sqcup}^{E_w}(a_1, b_1) \geq S_{\mathcal{A}-\sqcup}^{E_w}(a_2, b_2)$ .*

*Demostración.* Sin pérdida de generalidad se demuestra únicamente para la primera situación:  $w(a_1) \geq w(a_2)$  y  $w(b_1) \geq w(b_2)$  (la otra es análoga aprovechando la simetría de  $\mathcal{A}$ ). Supongamos primero que  $w(a_1 \sqcup b_1) = 0$ . Entonces, se tendría que necesariamente  $a_1$  y  $b_1$  son intervalos degenerados cumpliendo  $a_1 = b_1$ . Por los axiomas de similitud,  $S_{\mathcal{A}-\sqcup}^{E_w}(a_1, b_1) = 1$ , luego la desigualdad se satisface siempre.

Supongamos ahora que  $w(a_1 \sqcup b_1) > 0$ , entonces también se da  $w(a_2 \sqcup b_2) > 0$ . Utilizando la monotonía creciente por componentes de  $\mathcal{A}$ , se obtiene lo siguiente:

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^{E_w}(a_2, b_2) &= \mathcal{A}(E(a_2 \sqcup b_2, a_2), E(a_2 \sqcup b_2, b_2)) = \mathcal{A}\left(\frac{w(a_2)}{w(a_2 \sqcup b_2)}, \frac{w(b_2)}{w(a_2 \sqcup b_2)}\right) \\ &= \mathcal{A}\left(\frac{w(a_2)}{w(a_1 \sqcup b_1)}, \frac{w(b_2)}{w(a_1 \sqcup b_1)}\right) \leq \mathcal{A}\left(\frac{w(a_1)}{w(a_1 \sqcup b_1)}, \frac{w(b_1)}{w(a_1 \sqcup b_1)}\right) \\ &= \mathcal{A}(E(a_1 \sqcup b_1, a_1), E(a_1 \sqcup b_1, b_1)) = S_{\mathcal{A}-\sqcup}^{E_w}(a_1, b_1). \end{aligned}$$

□

Al igual que antes, se ilustra el resultado con un ejemplo.

**Ejemplo 4.17.** *Al igual que en el ejemplo 4.15, se consideran la incrustación  $E_w$  y la media aritmética. Las parejas de intervalos seleccionadas ahora son de la forma  $a_\delta = [0, 0.05 + \delta]$  y  $b_\delta = [0.95 - \delta, 1]$ , con  $\delta \in [0, 0.4]$ . En este caso, los intervalos son siempre disjuntos y a medida que aumenta el valor de  $\delta$ , el extremo superior de  $a_\delta$  y*

el extremo inferior de  $b_\delta$  están cada vez más próximos. Si se calcula la similitud para cada par, se llega a:




Figura 4.3: Valores de  $S_{\mathcal{A}-\sqcup}^{E_w}$  para cada par de intervalos  $a_\delta, b_\delta$ .

El comportamiento obtenido es el esperado: a pesar de que los intervalos sean siempre disjuntos, la similitud ofrece un valor mayor a medida que éstos están cada vez más próximos, de acuerdo con el pensamiento inicial al inicio de esta sección.

Por otro lado, como se vio en el capítulo 3, existen más incrustaciones aparte de  $E_w$ . Por ejemplo, las basadas en implicaciones, desarrolladas en la sección 3.2. Cabría preguntarse: ¿pueden encontrarse propiedades de monotonía similares a las presentadas para la incrustación  $E_w$ ? La respuesta es que sí. En particular, se estudiará la monotonía a partir de la relación de acotación entre los extremos de los intervalos, en lugar de recurrir a las amplitudes.

**Proposición 4.18.** Sea  $I$  una función de implicación,  $E_I$  la incrustación asociada y  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Dados  $a_1, a_2, b_1, b_2 \in \mathcal{L}([0, 1])$  tales que:

- $a_1 \preceq_{Lo} b_1$  y  $a_2 \preceq_{Lo} b_2$ ,
- $\underline{a_1} \leq \underline{a_2}$  y  $\underline{b_1} \geq \underline{b_2}$ ,
- $\overline{a_1} \leq \overline{a_2}$  y  $\overline{b_1} \geq \overline{b_2}$ ,

Entonces  $S_{\mathcal{A}-\sqcup}^{E_I}(a_1, b_1) \leq S_{\mathcal{A}-\sqcup}^{E_I}(a_2, b_2)$ .

*Demostración.* Es claro que

$$\begin{aligned} a_1 \sqcup b_1 &= [\text{mín}\{\underline{a}_1, \underline{b}_1\}, \text{máx}\{\overline{a}_1, \overline{b}_1\}] = [\underline{a}_1, \overline{b}_1], \\ a_2 \sqcup b_2 &= [\text{mín}\{\underline{a}_2, \underline{b}_2\}, \text{máx}\{\overline{a}_2, \overline{b}_2\}] = [\underline{a}_2, \overline{b}_2]. \end{aligned}$$

Por otro lado, la definición de la  $\sqcup$ -similitud es:

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^{E_I}(a, b) &= \mathcal{A}(E_I(a \sqcup b, a), E_I(a \sqcup b, b)) = \\ &= \mathcal{A}(\text{mín}\{I(\underline{a}, \underline{a \sqcup b}), I(\overline{a \sqcup b}, \overline{a})\}, \text{mín}\{I(\underline{b}, \underline{a \sqcup b}), I(\overline{a \sqcup b}, \overline{b})\}). \end{aligned}$$

Si se sustituye con lo comentado anteriormente y usando que  $I(x, y) = 1 \iff x \leq y$  para ver que  $I(\underline{a}_1, \underline{a}_1) = I(\overline{b}_2, \overline{b}_2) = 1$ , se llega a:

$$\begin{aligned} S_{\mathcal{A}-\sqcup}^{E_I}(a_1, b_1) &= \mathcal{A}(\text{mín}\{I(\underline{b}_1, \underline{a}_1), I(\overline{b}_1, \overline{b}_1)\}, \text{mín}\{I(\underline{a}_1, \underline{a}_1), I(\overline{b}_1, \overline{a}_1)\}) = \\ &= \mathcal{A}(I(\underline{b}_1, \underline{a}_1), I(\overline{b}_1, \overline{a}_1)), \\ S_{\mathcal{A}-\sqcup}^{E_I}(a_2, b_2) &= \mathcal{A}(\text{mín}\{I(\underline{b}_2, \underline{a}_2), I(\overline{b}_2, \overline{b}_2)\}, \text{mín}\{I(\underline{a}_2, \underline{a}_2), I(\overline{b}_2, \overline{a}_2)\}) = \\ &= \mathcal{A}(I(\underline{b}_2, \underline{a}_2), I(\overline{b}_2, \overline{a}_2)). \end{aligned}$$

Utilizando las propiedades de monotonía de esa misma definición, es directo comprobar que:

$$\begin{aligned} I(\underline{b}_1, \underline{a}_1) &\leq I(\underline{b}_2, \underline{a}_2), \\ I(\overline{b}_1, \overline{a}_1) &\leq I(\overline{b}_2, \overline{a}_2). \end{aligned}$$

Como las funciones de agregación son crecientes por componentes, se obtiene que

$\mathcal{A}(I(\underline{b}_1, \underline{a}_1), I(\overline{b}_1, \overline{a}_1)) \leq \mathcal{A}(I(\underline{b}_2, \underline{a}_2), I(\overline{b}_2, \overline{a}_2))$ , por lo que queda probado que

$$S_{\mathcal{A}-\sqcup}^{E_I}(a_1, b_1) \leq S_{\mathcal{A}-\sqcup}^{E_I}(a_2, b_2). \quad \square$$

A continuación se ilustra el resultado anterior con dos ejemplos idénticos a los empleados en el caso de  $E_w$ .

**Ejemplo 4.19.** *Se consideran la incrustación  $E_{EXP}$ , donde  $I_{EXP}$  es la implicación exponencial, y la media aritmética como función de agregación simétrica y 1-estricta. Se toman las familias de intervalos  $a_\delta = [\delta, \delta + 0.05]$  y  $b_\delta = [1 - \delta, 0.95 - \delta]$ , con  $\delta \in [0, 0.4]$ , al igual que en el ejemplo 4.8. Si se aplica la  $\sqcup$ -similitud, se obtiene:*




Figura 4.4: Valores de  $S_{T-\sqcup}^{EXP}$  para cada par de intervalos  $a_\delta, b_\delta$ .

Es claro como a medida que los pares  $a_\delta, b_\delta$  están más próximos, la similitud proporciona un valor mayor.

Por otro lado, se toma ahora la incrustación  $E_{IFD}$ , con  $I_{FD}$  la implicación de Fodor, y el mínimo como  $T$ -norma. Se consideran ahora los intervalos de la forma  $a_\delta = [0, 0.05 + \delta]$  y  $b_\delta = [0.95 - \delta, 1]$ , con  $\delta \in [0, 0.4]$ , como en el ejemplo 4.11. Aplicando la  $\sqcup$ -similitud, se llega a:




Figura 4.5: Valores de  $S_{A-\sqcup}^{EFD}$  para cada par de intervalos  $a_\delta, b_\delta$ .

También se consigue lo que se buscaba, un mayor valor de la similitud para intervalos disjuntos más próximos.

La proposición 4.18 utiliza el orden reticular. Para la relación de contenido, se tiene el siguiente resultado:

**Proposición 4.20.** *Sea  $I$  una función de implicación,  $E_I$  la incrustación asociada y  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Dados  $a_1, a_2, b_1, b_2 \in \mathcal{L}([0, 1])$  tales que:*

- $a_1 \subseteq b_1$  y  $a_2 \subseteq b_2$ ,
- $\underline{a_2} \leq \underline{a_1}$  y  $\underline{b_2} \geq \underline{b_1}$ ,
- $\overline{a_1} \leq \overline{a_2}$  y  $\overline{b_1} \geq \overline{b_2}$ .

Entonces  $S_{\mathcal{A}-\sqcup}^{E_I}(a_1, b_1) \leq S_{\mathcal{A}-\sqcup}^{E_I}(a_2, b_2)$ .

*Demostración.* Dados dos intervalos  $a, b \in \mathcal{L}[0, 1]$  con  $a \subseteq b$ , se tiene que

$$a \sqcup b = [\min\{\underline{a}, \underline{b}\}, \max\{\overline{a}, \overline{b}\}] = [\underline{b}, \overline{b}] = b.$$

Así, utilizando la definición de similitud y la propiedad de ordenación de la implicación se llega a:

$$S_{\mathcal{A}-\sqcup}^{E_I}(a, b) = \mathcal{A}(E_I(a \sqcup b, a), E_I(a \sqcup b, b)) = \mathcal{A}(E_I(b, a), E_I(b, b)) = \mathcal{A}(E_I(b, a), 1).$$

Al no tener  $a$  y  $b$  intersección vacía, se da que:

$$E_I(b, a) = \min\{I(\underline{a}, \underline{b}), I(\overline{b}, \overline{a})\}.$$

Particularizando ahora para la pareja de intervalos del enunciado, por las propiedades de monotonía de las implicaciones se consigue:

$$\begin{aligned} I(\underline{a_1}, \underline{b_1}) &\leq I(\underline{a_2}, \underline{b_2}), \\ I(\overline{b_1}, \overline{a_1}) &\leq I(\overline{b_2}, \overline{a_2}). \end{aligned}$$

Al ser las funciones de agregación crecientes por componentes, se obtiene que

$$\mathcal{A}(E_I(b_1, a_1), 1) \leq \mathcal{A}(E_I(b_2, a_2), 1), \text{ lo que prueba la desigualdad } S_{\mathcal{A}-\sqcup}^{E_I}(a_1, b_1) \leq S_{\mathcal{A}-\sqcup}^{E_I}(a_2, b_2).$$

□

De esta proposición puede concluirse también el siguiente corolario.

**Corolario 4.21.** *Sea  $I$  una función de implicación,  $E_I$  la incrustación asociada y  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Dados  $a_1, a_2, b_1, b_2 \in \mathcal{L}([0, 1])$  tales que:*

- $a_1 \subseteq b_1$  y  $a_2 \subseteq b_2$ ,
- $\underline{a_2} \leq \underline{a_1}$  y  $\underline{b_2} \geq \underline{b_1}$ ,
- $\overline{a_1} \leq \overline{a_2}$  y  $\overline{b_1} \geq \overline{b_2}$ .

Entonces  $S_{\mathcal{A}}^{E_I}(a_1, b_1) \leq S_{\mathcal{A}}^{E_I}(a_2, b_2)$ .

*Demostración.* Basta con aplicar la proposición 4.10 al resultado anterior.  $\square$

Otro punto clave en este trabajo es que el buen comportamiento de las similitudes basadas en incrustaciones no está garantizado al trabajar con intervalos degenerados. Incluso al considerar una medida de incrustación tan intuitiva como la basada en la amplitud de los intervalos involucrados,  $E_w$ , y la similitud  $\sqcup$ -agregada, esta no es capaz de proporcionar un grado de similitud distinto de 0 al considerar intervalos diferentes de amplitud nula.

**Lema 4.22.** *Sea  $E_w$  la medida de incrustación basada en la amplitud y sea  $\mathcal{A}$  una función de agregación simétrica y 1-estricta. Sean  $a, b \in \mathcal{L}([0, 1])$  tales que  $w(a) = 0$  y  $w(b) = 0$ . Entonces se tiene que:*

$$S_{\mathcal{A}-\sqcup}^{E_w}(a, b) = \begin{cases} 1 & \text{si } a = b \\ 0 & \text{en otro caso} \end{cases}$$

*Demostración.* Se consideran dos casos:

- Si  $a = b$ , por ser  $S_{\mathcal{A}-\sqcup}^{E_w}$  una medida de similitud, tenemos que  $S_{\mathcal{A}-\sqcup}^{E_w}(a, b) = 1$ .
- Si  $a \neq b$ , entonces  $E_w(a \sqcup b, a) = E_w(a \sqcup b, b) = 0$ . Así,

$$S_{\mathcal{A}-\sqcup}^{E_w}(a, b) = \mathcal{A}(0, 0) = 0.$$

$\square$

Una de las grandes ventajas de las medidas de incrustación basadas en implicaciones es que permiten construir similitudes que resulten informativas al trabajar incluso con intervalos degenerados. Para probarlo, resulta imprescindible la propiedad de mínima falsedad, tal y como refleja el siguiente resultado.

**Corolario 4.23.** *Dada una función de implicación  $I$  que verifica la propiedad de mínima falsedad, se tiene que:*

$$E_I(a, b) = 0 \iff a \cap b = \emptyset \text{ o } a = [0, 1], b \in \{[0, 0], [1, 1]\}.$$

*Demostración.* La implicación de derecha a izquierda se deduce directamente de la definición de  $E_I$  y la propiedad  $I(1, 0) = 0$ . En cuanto al otro sentido, es claro que, si  $a \cap b \neq \emptyset$ ,  $E_I(a, b) = \min\{I(\underline{b}, \underline{a}), I(\bar{a}, \bar{b})\} = 0 \implies I(\underline{b}, \underline{a}) = 0$  o  $I(\bar{a}, \bar{b}) = 0$ . Como  $I$  cumple la propiedad de mínima falsedad, se obtiene que:

- Si  $\underline{b} = 1$  y  $\underline{a} = 0$ , entonces  $b = [1, 1]$  y  $a = [0, \bar{a}]$ .
- Si  $\bar{a} = 1$  y  $\bar{b} = 0$ , entonces  $b = [0, 0]$  y  $a = [\underline{a}, 1]$ .

Se deduce directamente que, para ambos casos, la única forma de que  $a \cap b \neq \emptyset$  es que  $a = [0, 1]$ , luego queda demostrada la implicación de izquierda a derecha.  $\square$

Atendiendo a todas las implicaciones mencionadas en el trabajo, es directo comprobar que las únicas que verifican la propiedad de mínima falsedad son las de Łukasiewicz y Fodor, y por tanto su incrustación asociada cumple el corolario anterior.

La proposición que se muestra a continuación prueba que, considerando implicaciones que satisfagan la propiedad de mínima falsedad y funciones de agregación 0-estrictas, es posible construir similitudes que no proporcionan el valor 0 siempre que se comparan intervalos degenerados disjuntos.

**Proposición 4.24.** *Dada una función de implicación  $I$  que verifica la propiedad de mínima falsedad y una función de agregación  $\mathcal{A}$  simétrica, 1-estricta y 0-estricta, se verifica:*

$$S_{\mathcal{A}-\sqcup}^{E_I}(a, b) = 0 \iff \{a, b\} = \{[0, 0], [1, 1]\} .$$

*Demostración.* Sean  $a, b \in \mathcal{L}([0, 1])$  tales que  $S_{\mathcal{A}-\sqcup}^{E_I}(a, b) = 0$ . Por la definición de la similitud, se tiene que  $\mathcal{A}(E_I(a \sqcup b, a), E_I(a \sqcup b, b)) = 0$ . Como  $\mathcal{A}$  es 0-estricta, esto es equivalente a que  $E_I(a \sqcup b, a) = E_I(a \sqcup b, b) = 0$ . Ahora bien, por el corolario 4.23, como  $I$  es de mínima falsedad y  $a \sqcup b$  contiene a  $a$  y a  $b$ :

- $E_I(a \sqcup b, a) = 0 \iff a \sqcup b = [0, 1], a \in \{[0, 0], [1, 1]\},$
- $E_I(a \sqcup b, b) = 0 \iff a \sqcup b = [0, 1], b \in \{[0, 0], [1, 1]\}.$

Es claro que las únicas opciones para que  $a \sqcup b = [0, 1]$  son que  $a = [0, 0]$  y  $b = [1, 1]$ , o  $a = [1, 1]$  y  $b = [0, 0]$ .

Recíprocamente, si  $\{a, b\} = \{[0, 0], [1, 1]\}$ , entonces  $a \sqcup b = [0, 1]$ . Por tanto,  $E_I(a \sqcup b, a) = E_I(a \sqcup b, b) = 0$ , y, en consecuencia,  $S_{\mathcal{A}-\sqcup}^{E_I}(a, b) = \mathcal{A}(0, 0) = 0$ .

$\square$



Gracias a este resultado, se alcanza el objetivo más ambicioso: disponer de medidas de similitud que nunca den como resultado 0, ni siquiera para pares de intervalos disjuntos o degenerados, reservando ese valor para el caso extremo en el que coinciden con los intervalos degenerados  $[0, 0]$  y  $[1, 1]$ . Se consigue así extender la noción difusa de semejanza a todo par de intervalos en  $\mathcal{L}([0, 1])$ , sin importar su intersección o su amplitud, algo que medidas como la de Jaccard no eran capaces de lograr.

Se ilustra este último resultado con el siguiente ejemplo:

**Ejemplo 4.25.** *Se consideran las similitudes  $\sqcup$ -agregadas construidas a partir de las incrustaciones de Lukasiewicz y Fodor, siendo  $\mathcal{A}$  la media aritmética, que es una función de agregación simétrica, 1-estricta y 0-estricta. Aplicándolas a diferentes pares de intervalos degenerados, se obtiene:*

Tabla 4.3: Resultados de  $S_{\mathcal{A}-\sqcup}^{ELK}$  y  $S_{\mathcal{A}-\sqcup}^{EFD}$  aplicadas a parejas de intervalos degenerados.

| Par de intervalos            | $S_{\mathcal{A}-\sqcup}^{ELK}$ | $S_{\mathcal{A}-\sqcup}^{EFD}$ |
|------------------------------|--------------------------------|--------------------------------|
| $[0, 0], [1, 1]$             | 0                              | 0                              |
| $[0.2, 0.2], [0.4, 0.4]$     | 0.8                            | 0.6                            |
| $[0.3, 0.3], [0.7, 0.7]$     | 0.6                            | 0.3                            |
| $[0.15, 0.15], [0.75, 0.75]$ | 0.4                            | 0.25                           |

*Se observa como las similitudes únicamente dan 0 en el caso extremo, tal y como afirma la proposición 4.24.*

Sintetizando, el capítulo comenzó discutiendo la motivación de las similitudes como herramienta para comparar intervalos, y posteriormente se expuso una forma sencilla de obtenerlas a partir de las incrustaciones. Tras varios ejemplos donde se verificaba su correcto funcionamiento en situaciones generales, se hicieron notar algunas de sus limitaciones, en especial si la pareja de intervalos era disjunta. Se propusieron entonces unas nuevas funciones de similitud que, basadas en la envolvente convexa, tenían como objetivo establecer grados de comparación no triviales entre dicha clase de intervalos. Se demostró que, tanto para la incrustación basada en la amplitud como para las basadas en implicaciones, estos nuevos operadores cumplían con el objetivo para intervalos no degenerados. Finalmente, imponiendo la propiedad de implicación de mínima falsedad y la condición de ser 0-estricta a la función de agregación, se obtuvo una clase de

similitudes capaz de asignar valores no nulos en una gama más amplia de situaciones, incluyendo ciertos casos de intervalos degenerados. De este modo, con una construcción sencilla y exigiendo alguna que otra propiedad adicional, fue posible extender la comparación (no trivial) de intervalos a todas las combinaciones posibles de  $\mathcal{L}([0, 1])$ , lo cual se le resistía a otras similitudes tradicionales.

Todo este desarrollo teórico ha permitido disponer de una herramienta bastante sencilla, versátil y potente, que permite tratar de manera natural y rigurosa datos intervalares. Es por ello que la segunda parte de este trabajo propondrá una posible aplicación de estos operadores de similitud en el contexto de los métodos de pronóstico, en particular las series temporales.

# Capítulo 5

## Aplicación a series temporales intervalares

Recapitulando todo lo expuesto hasta ahora, se ha expuesto el formalismo de la lógica difusa o fuzzy, particularizando en el caso de los intervalos. Se focalizó en la extensión de la relación de contenido entre intervalos, obteniendo las incrustaciones. Finalmente, se construyeron diversas medidas de similitud basándose en esos operadores y se propuso una modificación que solventase casos problemáticos. En esta segunda parte del trabajo, se procederá a poner en práctica dicho desarrollo teórico. En concreto, se trabajará en el ámbito de las series temporales intervalares, y se estudiará cómo dichas similitudes pueden mejorar la predicción en comparación a otros modelos clásicos.

Primeramente, se expondrán los fundamentos de las series temporales, para posteriormente explicar brevemente *ARIMA*, el método clásico por excelencia. Finalmente, se hablará de las series temporales difusas, siendo ahí donde introduciremos las similitudes para concluir con dos ejemplos basados en datos reales.

### 5.1. Series temporales: fundamento teórico

#### 5.1.1. Definición y conceptos básicos

Para redactar esta sección de fundamentos, se utilizó como base [\[12\]](#). Una serie temporal se define como una sucesión de datos tomados cronológicamente. Desde el

punto de vista probabilístico, se modeliza como una sucesión de variables aleatorias, identificadas con un parámetro que es creciente con el tiempo. Posee una estructura interna bien definida, cuyos componentes son los siguientes:

- **Tendencia:** es el aumento o disminución a largo plazo de los datos, que puede ser lineal o no.
- **Estacionalidad:** es el fenómeno por el cual la serie se ve afectada por factores relacionados con el instante de tiempo en el que se toman los datos (por ejemplo, en qué mes del año se tomaron). Posee una frecuencia fija y conocida.
- **Ciclos:** son las subidas y bajadas sin frecuencia fija que sufre la serie. Su duración suele ser en promedio mayor que la duración de un patrón estacional.
- **Ruido:** es la variación aleatoria de la serie.

Se ilustra esto con el siguiente ejemplo:

**Ejemplo 5.1.** *Se considera la serie temporal `a10`, incluida en el paquete `fpp2` de `R`, que recoge los gastos mensuales en fármacos antidiabéticos en Australia entre 1991 y 2008. Es posible descomponerla en sus componentes, de forma que se obtiene:*




Figura 5.1: Serie temporal junto a su tendencia, estacionalidad y ruido.

*Es claro como dicha serie temporal posee una tendencia creciente y una estacionalidad clara, además de cierto ruido fruto de la aleatoriedad. No es apreciable ningún ciclo.*

Para estudiarla y realizar predicciones, dicha serie se modeliza de la siguiente manera:

$$y_t = f(S_t, T_t, E_t) \quad (5.1)$$

Siendo  $y_t$  los datos de la serie en el instante  $t$ ,  $S_t$  la componente estacional en dicho momento,  $T_t$  el término que contiene la información tanto de la tendencia como de los ciclos, y finalmente  $E_t$  la componente asociada al ruido. Los modelos más comunes son:

- Descomposición aditiva:  $y_t = S_t + T_t + E_t$ .
- Descomposición multiplicativa:  $y_t = S_t \cdot T_t \cdot E_t$ .

El modelo aditivo es más adecuado si el patrón estacional no varía con el tiempo. Es posible, y a veces conveniente, pasar de un modelo a otro, o incluso a nuevos modelos, mediante transformaciones como la de Box-Cox, permitiendo reducir varianzas o sesgos.

Una vez hecho un estudio descriptivo de la serie e identificado sus componentes, se procede al pronóstico. Primeramente, se dividen los datos disponibles en dos conjuntos: uno de entrenamiento o *train* (en torno al 80 %) y otro de prueba o *test* (el 20 % restante). Es conveniente que el conjunto de prueba sea al menos tan grande como el horizonte máximo de predicción requerido. Además, es importante resaltar que un modelo cuyo desempeño sea bueno con los datos de entrenamiento no tiene por qué funcionar correctamente con los de prueba (no generaliza y solo memoriza los datos del entrenamiento, lo que se conoce como *overfitting* o sobreajuste).

Es posible estimar cada observación de la serie únicamente con las observaciones previas. Estos valores se conocen como valores ajustados y se denotan por  $\hat{y}_{t|t-1}$  o simplemente  $\hat{y}_t$ , que quiere decir que se predice el valor de  $y_t$  usando las observaciones  $y_1, \dots, y_{t-1}$ . Por esto, se dice que son pronósticos a un paso. Es importante resaltar que no siempre coinciden con los pronósticos reales, pues si el horizonte de predicción es mayor que 1 el modelo necesita basarse en sus propias predicciones para pronosticar valores futuros. Además, si el modelo involucra algún parámetro a estimar, dicha estimación se hace teniendo en cuenta todos los valores disponibles, incluidas observaciones posteriores al tiempo  $t$ .

Utilizando estos valores ajustados se definen los residuos de las series temporales:

$$e_t = y_t - \hat{y}_t. \quad (5.2)$$

Es importante resaltar que estos residuos se calculan en el conjunto de entrenamiento, y son útiles para ver si un modelo captura adecuadamente la información de los datos. Para que un método de pronóstico funcione correctamente, es conveniente que dichos residuos cumplan las siguientes propiedades:

- $\{e_t\}$  **no estén correlacionados**. Si ocurriese, existiría información en ellos que se podría utilizar para mejorar el modelo.
- $\{e_t\}$  sean **insesgados** (tengan media 0). Si no se da, basta sumar el valor de dicha media a los pronósticos para corregir ese sesgo.
- $\{e_t\}$  tengan **varianza constante**.
- $\{e_t\}$  sigan una **distribución normal**.

Por otro lado, una vez se tiene el modelo entrenado, se pasa a trabajar con los datos de prueba. En este caso se estudian los errores de pronóstico, definidos como la diferencia entre la observación y la predicción del modelo para un instante determinado:

$$e = y_{T+h} - \hat{y}_{T+h}, \quad (5.3)$$

donde los datos de entrenamiento son  $\{y_1, \dots, y_t\}$  y los de prueba  $\{y_{T+1}, y_{T+2}, \dots\}$ . Es clara la diferencia entre estos errores y los residuos, pues los primeros se utilizan en el entrenamiento y son pronósticos a un paso, mientras que los segundos se calculan en el conjunto de prueba y pueden ser a múltiples pasos.

Para evaluar el desempeño del modelo, se utilizan diferentes métricas sobre los errores de pronóstico. Algunos de los más comunes son:

- Errores dependientes de la escala: como su propio nombre indica, están en la misma escala de los datos, luego no pueden usarse para comparar series en diferentes unidades. El más representativo es la **raíz del error cuadrático medio**:  $RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n e_t^2}$ .
- Errores porcentuales: tienen la ventaja de que, al medirse en porcentajes, las unidades de la serie son irrelevantes. El más utilizado es el **error absoluto porcentual medio**:  $MAPE = \frac{100}{n} \cdot \sum_{t=1}^n \left| \frac{e_t}{y_t} \right|$ .

Con todo esto, ya es posible establecer el procedimiento habitual en series temporales. Primero se divide el conjunto de datos en entrenamiento y prueba. Se entrenan diferentes modelos y se estudian los errores de pronóstico de cada uno en el conjunto de prueba. De esta forma, se escoge el que mejor desempeño tenga y se entrena con

la serie completa. Se procede entonces a estudiar los residuos. Si su comportamiento es adecuado, ya se puede utilizar dicho modelo (ajustado a la serie completa) para predecir nuevos valores. De lo contrario, se pasa al segundo mejor modelo y lleva a cabo el mismo proceso.

### 5.1.2. ARIMA

Dentro de los métodos clásicos de predicción en series temporales, destaca ARIMA, cuyas siglas en inglés significan Modelos Autorregresivos Integrados de Media Móvil, y se aplica a series estacionarias.

**Definición 5.1.** [12] *Una serie  $\{y_t\}$  se dice estacionaria si, para todo  $s$ , la distribución de  $(y_t, \dots, y_{t+s})$  no depende del valor de  $t$ .*

Se caracterizan por la ausencia de tendencia y estacionalidad y una varianza relativamente constante. En la práctica, la mayoría no suelen serlo, pero existen diversas técnicas que permiten alcanzar dicha estacionariedad. Por ejemplo, las transformaciones de Box-Cox permiten estabilizar la varianza. Para eliminar la influencia de la tendencia y la estacionalidad, se recurre a las diferenciaciones. Antes de explicarlas, se introduce la siguiente notación:

**Notación 5.1.** [12] *Se define el operador de desplazamiento temporal (backward shift)  $B$  como el que actúa de la siguiente manera:*

$$By_t = y_{t-1} \implies B^n y_t = y_{t-n}.$$

Para estabilizar una serie con tendencia, se recurre a diferenciaciones ordinarias:

$$y'_t = y_t - y_{t-1} = (1 - B)y_t.$$

La nueva serie, llamada serie diferenciada, suele por lo general tener menor tendencia y ser más estacionaria que la original. Si no fuese estacionaria, se podrían diferenciar los datos otra vez hasta conseguir el comportamiento deseado. Si, por otro lado, la serie es estacional, se recurre a la diferenciación estacional:

$$y_t^{*} = y_t - y_{t-m} = (1 - B^m)y_t,$$

donde  $m$  indica el número de observaciones entre dos instantes relacionados estacionalmente (por ejemplo, si son datos mensuales,  $m = 12$ ).

Tal y como se mencionó anteriormente, el acrónimo ARIMA refleja la combinación de modelos autorregresivos con modelos de media móvil. A continuación se explican brevemente cada uno de ellos:

**Definición 5.2.** [12] *Dada una serie estacionaria  $\{y_t\}$ , un modelo autorregresivo  $AR(p)$  es un modelo de regresión múltiple donde se pronostica una variable mediante una combinación lineal de sus  $p$  valores previos (llamados retardos):*

$$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + e_t \iff (1 - \phi_1 B - \dots - \phi_p B^p) y_t = c + e_t,$$

siendo  $e_t$  ruido blanco, es decir, insesgados, incorrelados y con varianza constante (a menudo se suele exigir  $e_t \sim \mathcal{N}(0, \sigma^2)$ ).

**Definición 5.3.** [12] *Dada una serie estacionaria  $\{y_t\}$ , un modelo de media móvil  $MA(q)$  es un modelo similar a una regresión múltiple que utiliza los errores de pronóstico de los  $q$  instantes previos para predecir la variable:*

$$y_t = c + \theta_1 e_{t-1} + \dots + \theta_q e_{t-q} + e_t \iff y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q) e_t,$$

donde  $e_t$  es ruido blanco. No es una regresión en el sentido habitual porque no se observan los valores de  $e_t$ .

Combinando ambos, se obtienen los modelos *ARMA* no estacionales:

**Definición 5.4.** [12] *Dada una serie estacionaria  $\{y_t\}$ , un modelo autoregresivo de media móvil  $ARMA(p, q)$  se define como:*

$$(1 - \phi_1 B - \dots - \phi_p B^p) y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q) e_t.$$

Si la serie no posee estacionalidad y tampoco es estacionaria, habrá que aplicar un número determinado de diferenciaciones ordinarias. Combinando esto con un modelo *ARMA*, se llega al modelo *ARIMA* no estacional:

**Definición 5.5.** [12] *Dada  $\{y_t\}$  una serie no estacional, se define el modelo *ARIMA*  $(p, d, q)$  como la combinación de un modelo  $ARMA(p, q)$  con una diferenciación ordinaria de grado  $d$ , de forma que dicha serie diferenciada sea estacionaria, es decir,  $y_t \equiv ARIMA(p, d, q) \iff (1 - B)^d y_t \equiv ARMA(p, q)$ . Su expresión general es:*

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - B)^d y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q) e_t.$$



Ahora bien, para incluir series temporales con estacionalidad, es necesario definir el modelo *ARIMA* estacional o general, denotado como  $ARIMA(p, d, q)(P, D, Q)_m$ . El término  $(P, D, Q)_m$  es el que añade la información de la estacionalidad, donde  $m$  vuelve a ser el número de observaciones entre dos momentos relacionados estacionalmente. En la práctica, consiste en realizar otro *ARIMA* más, pero sobre la parte estacional, de manera que ahora los retrocesos no se hacen a los instantes previos, sino a los instantes análogos de periodos estacionales anteriores, y las diferenciaciones pasan a ser estacionales en lugar de ordinarias. La definición formal es la siguiente:

**Definición 5.6.** [12] *Dada una serie  $\{y_t\}$ , se define el modelo  $ARIMA(p, d, q)(P, D, Q)_m$ , donde  $(p, d, q)$  indica la parte no estacional y  $(P, D, Q)_m$  la estacional, de la siguiente manera:*

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - \Phi_1 B^m - \dots - \Phi_P B^{mP})(1 - B)^d(1 - B^m)^D y_t = c + (1 + \theta_1 B + \dots + \theta_q B^q)(1 + \Theta_1 B^m + \dots + \Theta_Q B^{mQ})e_t.$$

Es claro que  $ARIMA(p, d, q)(0, 0, 0)_m = ARIMA(p, d, q)$ .

Ahora bien, surge la cuestión de cómo escoger los valores adecuados de los parámetros  $d, p, q, D, P, Q$ . Los softwares informáticos suelen incluir comandos que realizan automáticamente dicho proceso, pero se podría obtener manualmente el modelo adecuado con el algoritmo de Hyndman y Khandakar [12].

Con el modelo adecuado elegido, se procede finalmente al estudio de los residuos. Como ya se mencionó anteriormente, deben comportarse como ruido blanco, es decir, que sean insesgados e incorrelados, y con distribución normal y varianza estable e incorrelados.

Si los residuos no se comportan adecuadamente, pasaríamos a evaluar los del segundo modelo con mejor desempeño. Si, por el contrario, sí lo hacen, se pasaría a la predicción. Así, se reescribe la ecuación 5.6 para que  $y_t$  esté solo en un lado de la igualdad y se reemplaza  $t$  por  $T + h$ , con  $h = 1, 2, 3, \dots$ , sustituyendo las observaciones futuras por sus predicciones, los errores futuros por cero, y los errores pasados por sus residuos correspondientes.

### 5.1.3. Series temporales difusas

Para esta sección, se utilizaron las referencias [5], [17] y [20]. Los métodos clásicos vistos en la sección anterior, como *AR*, *MA*, *ARMA* o *ARIMA*, funcionan bastante bien en numerosas situaciones. Sin embargo, están basados en postulados estadísticos bastante rígidos, principalmente la linealidad de los datos. En la práctica, condiciones como esa no son siempre satisfechas, por lo que la capacidad predictiva de estos modelos comienza a verse mermada. Debido a eso, en la década de 1990, con el desarrollo de la lógica difusa propuesta por Zadeh, se introdujeron las llamadas series temporales difusas (FTS por sus siglas en inglés), un enfoque diferente al estadístico tradicional y que ha mostrado una buena precisión, una fácil interpretabilidad y poca complejidad computacional.

La idea básica detrás de las FTS es relativamente simple. Primero se va a explicar el funcionamiento general, y posteriormente se particularizará para este trabajo. Se comienza así con la fase de entrenamiento, que se ilustra en la siguiente figura:




Figura 5.2: Etapas del entrenamiento de una FTS [17].

Dada una serie temporal  $y_t \in \mathbb{R}$ , con  $t = 0, 1, \dots, T$ , se define el universo de discurso  $U$ , que no es más que un intervalo en la recta real que contiene todos los valores que toma la variable  $y_t$ . Aunque, a priori, se podría tomar  $U = [\min\{y_t\}, \max\{y_t\}]$ , se suele dar cierto margen por si la serie excediese esos límites en futuras observaciones. Es decir, se toma  $U = [\min\{y_t\} - D_1, \max\{y_t\} + D_2]$ . Algunas de las opciones más utilizadas en la literatura son:

- $D_1 = r \cdot \min\{y_t\}$ ,  $D_2 = r \cdot \max\{y_t\}$ , con  $0 < r < 1$ .

- $D_1 = D_2 = r \cdot (\max\{y_t\} - \min\{y_t\})$  (esta será la utilizada en los ejemplos).

El valor de  $r$  no está unívocamente determinado. Algunos autores suelen establecer  $r = 0.2$ , aunque lo más conveniente es fijarlo en función del problema [27].

Una vez definido el universo de discurso, se define la variable lingüística  $\tilde{A}$ . Es un elemento principal de la FTS, pues es la que contiene las categorías a partir de las cuales se crearán los conjuntos difusos  $A_1, \dots, A_n$ . Por ejemplo, si se dispone de una serie temporal de temperaturas, se podría definir una variable lingüística que tuviese a las categorías: “frío”, “templado” y “caliente”, a partir de los cuales se crearían los respectivos conjuntos difusos. El número óptimo y su forma es un tema con múltiples aristas y mucha investigación detrás, para más información consultar la bibliografía de este capítulo.

Para construir esos conjuntos difusos se les asigna una función de membresía, que cuantifique la pertenencia de un elemento a dicho conjunto. Las más básicas y utilizadas son la triangular (como en la figura 5.2) o la trapezoidal. De este modo, cada valor de la serie se le asociaría un número en  $[0, 1]$  para cada conjunto difuso, que sería su grado de pertenencia. Se selecciona el mayor grado de pertenencia, y entonces a ese dato se le asigna el conjunto difuso correspondiente. Este procedimiento se conoce como fuzzificación (*fuzzyfication* en inglés).

Se lleva a cabo este proceso con todos los datos de la serie y se establecen las relaciones lógicas difusas (FLR), que se definen como una secuencia temporal de los conjuntos difusos en base al orden de los datos de la serie temporal inicial. Esto sería propiamente la serie temporal difusa.

Para acabar el entrenamiento, lo que se hace es establecer los grupos de relaciones lógicas difusas (FLRG). Tal y cómo se aprecia en la imagen, esto no es más que, para conjunto difuso, recopilar que otros le suceden en la FTS.

El entrenamiento ya estaría terminado, ahora vendría la parte de la predicción de la serie. Al igual que antes, se ilustra con un esquema gráfico:




Figura 5.3: Etapas de la predicción de una FTS. Imagen de [17].

Se quiere pronosticar el valor de la serie en un instante determinado. Para ello, se toma el punto de la serie inmediatamente anterior (que se conoce o se ha predicho previamente). Se le asigna entonces el conjunto difuso correspondiente mediante la pertenencia difusa máxima, y se observan las reglas del FLRG. El paso final sería la defuzzificación (*defuzzification* en inglés), es decir, dar una predicción numérica en base a las relaciones entre los conjuntos difusos. Existen múltiples métodos, a continuación se exponen dos de los más básicos:

- **Método de Chen:** dados los conjuntos difusos a los que se asociaría la observación que queremos pronosticar, se toman los puntos con mayor membresía de cada uno (si se usa la membresía triangular, serían los centrales). Se hace una media aritmética de ambos, y ese es el pronóstico.
- **Método de Cheng:** análogo a Chen, solo que en lugar de hacer una media aritmética se hace una media ponderada, donde los pesos son las frecuencias de aparición de la relación  $A_i \rightarrow A_j$  en el entrenamiento.

A diferencia de los modelos ARIMA, en las FTS no se exige que los errores se comporten como ruido blanco bajo un modelo probabilístico concreto. Por ello, aunque pueden calcularse errores de predicción, estos no desempeñan el mismo papel diagnóstico que los residuos en ARIMA. ARIMA busca modelar la serie de forma que el valor en un instante concreto depende linealmente de los valores y errores pasados (a excepción de un ligero ruido aleatorio). Debido a esto, si los residuos no son ruido blanco, significa que toda la estructura explicable de la serie no está siendo captado por el modelo, luego

no es el idóneo. Ahora bien, las FTS no siguen esa estructura, sino que establecen reglas entre categorías difusas. De esta forma, no modelan la serie separando el patrón de la variación aleatoria residual, sino que ya en el propio uso de la lógica difusa trabaja con dicha incertidumbre.

## 5.2. Método para FTS intervalares

La propuesta de este trabajo consiste en extender los algoritmos de FTS a series temporales intervalares, es decir, a series cuyas observaciones no son números, sino intervalos. Uno de los grandes problemas a la hora de emplear intervalos, como ya se ha mencionado en varias ocasiones, es que no es tan directo establecer cuánto se parecen entre sí. Esta fue la motivación de la primera parte del trabajo, donde se desarrollaron medidas de similitud basadas en incrustaciones como herramienta para comparar intervalos.

Así, se propone una variación de los métodos de FTS que permita trabajar con series temporales intervalares. En primer lugar, se define el universo de discurso y se construye una familia de categorías representadas mediante intervalos  $A_1, \dots, A_n$ , de forma análoga al caso puntual. A continuación, en lugar de asignar una observación a un conjunto difuso mediante un grado de pertenencia clásico, se comparará cada observación intervalar con los intervalos  $A_j$  mediante las medidas de similitud desarrolladas en los capítulos anteriores. De esta forma se obtiene una secuencia de estados a partir de la cual se construyen las FLR y los FLRG. Es importante recalcar que, para poder aplicar las similitudes, es imprescindible normalizar previamente los datos, de forma que pertenezcan a  $\mathcal{L}([0, 1])$ .

Tal y como se mostró previamente, se pueden formar una gran cantidad de similitudes a partir de incrustaciones. Debido a ello, para esta parte se usarán únicamente aquellas que emplean la media aritmética como función de agregación simétrica y 1-estricta.

Para el proceso de pronóstico, como se busca que dicha predicción sea intervalar, se aplicará el proceso de defuzzificación explicado anteriormente a los extremos de los intervalos consecuentes. Como los mismos pesos se aplican al extremo inferior y al extremo superior, la predicción obtenida vuelve a ser un intervalo bien definido. Se

emplearán cinco métodos de defuzzificación. Por un lado, Chen y Cheng, ya explicados previamente. Por el otro, teniendo en cuenta que las similitudes son el objeto central de este trabajo, se proponen los siguientes tres:

- **Método SIM 1:** se hace una media ponderada, donde los pesos se obtienen normalizando los valores de similitud entre la última observación y los intervalos  $A_j$  que aparecen como consecuentes en el FLRG.
- **Método SIM 2:** combina los métodos de Cheng y SIM 1, tomando como pesos la media aritmética entre las frecuencias normalizadas y los pesos normalizados de similitud.
- **Método SIM 3:** es análogo a SIM 2, pero combina las frecuencias y las similitudes mediante la media geométrica, normalizando después los pesos resultantes.

En todos los casos, los pesos se normalizan para que su suma sea igual a 1.

Para ilustrar esos métodos, se utiliza el siguiente ejemplo:

**Ejemplo 5.2.** *Dada una observación de la serie temporal  $a = [\underline{a}, \bar{a}]$ , se quiere hacer una predicción del siguiente dato, denotado por  $b = [\underline{b}, \bar{b}]$ . Supongamos que el universo de discurso se divide en los conjuntos  $A_j = [\underline{A}_j, \bar{A}_j]$ . Tras haber aplicado la similitud  $S$  al intervalo  $a$  y los conjuntos  $A_j$  (para aplicarla se normalizaron antes), se tiene que el mayor valor se da con  $S(a, A_2)$ . Se busca entonces en el FLRG y se encuentra que la relación es la siguiente:*

$$A_2 \longrightarrow A_2, A_3, A_5.$$

*Entonces, los procedimientos de defuzzificación actuarían de la siguiente forma. Se especifica únicamente el extremo inferior, pues el extremo superior se obtiene de forma análoga. Sea  $J = \{2, 3, 5\}$  el conjunto de índices que aparecen como consecuentes en el FLRG.*

- **Chen:**

$$\underline{b} = \frac{1}{3} (\underline{A}_2 + \underline{A}_3 + \underline{A}_5).$$

- **Cheng:** si  $f_i$  denota la frecuencia de aparición de la relación  $A_2 \rightarrow A_i$ , se consideran las frecuencias normalizadas

$$\tilde{f}_i = \frac{f_i}{\sum_{j \in J} f_j}, \quad i \in J.$$

Entonces,

$$\underline{b} = \tilde{f}_2 \underline{A}_2 + \tilde{f}_3 \underline{A}_3 + \tilde{f}_5 \underline{A}_5.$$

- **SIM 1:** se consideran los pesos de similitud normalizados

$$\tilde{s}_i = \frac{S(a, A_i)}{\sum_{j \in J} S(a, A_j)}, \quad i \in J.$$

Entonces,

$$\underline{b} = \tilde{s}_2 \underline{A}_2 + \tilde{s}_3 \underline{A}_3 + \tilde{s}_5 \underline{A}_5.$$

- **SIM 2:** se toman como pesos

$$w_i = \frac{\tilde{f}_i + \tilde{s}_i}{2}, \quad i \in J.$$

Entonces,

$$\underline{b} = w_2 \underline{A}_2 + w_3 \underline{A}_3 + w_5 \underline{A}_5.$$

- **SIM 3:** se combinan las frecuencias y las similitudes mediante

$$\nu_i = \frac{\sqrt{\tilde{f}_i \tilde{s}_i}}{\sum_{j \in J} \sqrt{\tilde{f}_j \tilde{s}_j}}, \quad i \in J.$$

Entonces,

$$\underline{b} = \nu_2 \underline{A}_2 + \nu_3 \underline{A}_3 + \nu_5 \underline{A}_5.$$

Finalmente, a la hora de evaluar el desempeño de los modelos, se utilizarán varias métricas. Primero se emplearán métricas clásicas, en particular el RMSE y el MAPE. No obstante, en el caso de la serie de precios eléctricos (uno de los dos ejemplos que trataremos más adelante), el MAPE debe interpretarse con cautela, ya que la presencia de valores negativos o próximos a cero dificulta su interpretación como error porcentual. Ahora bien, son unipuntuales, no intervalares, luego se aplicarán a cada extremo del intervalo. Surge entonces la siguiente problemática: podría ocurrir que la predicción del extremo inferior sea excelente, pero la del superior pésima. Sería interesante disponer de otra métrica global, que valorase el acierto del intervalo en su totalidad y no simplemente sus extremos por separado. Es inevitable entonces pensar, de nuevo, en las similitudes. Se utilizará así, como última métrica, la media aritmética de los valores obtenidos al aplicar la similitud entre la predicción y el valor real. La función de similitud empleada para esta métrica se construyó usando el mínimo como t-norma y la incrustación basada en la amplitud del intervalo.

Finalmente, para poder evaluar también el desempeño de estos nuevos métodos, se propone comparar su rendimiento con el que ofrece ARIMA. En concreto, se aplicará un

ARIMA a la serie temporal de extremos superiores, y otro al de extremos inferiores, y se obtendrán intervalos combinando las predicciones de ambos. Así, se podrán discutir los resultados de ambos modelos, y las ventajas operativas de uno respecto al otro.

### 5.2.1. Ejemplo 1: predicción de temperaturas

El primer conjunto de datos con el que se probarán los métodos desarrollados previamente será una serie de 28 observaciones de las temperaturas máximas y mínimas diarias en Oviedo, Asturias. Estos valores fueron recogidos por la AEMET<sup>1</sup> gracias a la estación meteorológica 1249X (El Cristo/zona universidad). Así, cada día entre el 1 y el 28 de marzo de 2026, se recogieron los datos sobre temperaturas máximas y mínimas, de forma que se dispone de observaciones intervalares diarias. A continuación, se muestra un gráfico de la serie:




Figura 5.4: Temperaturas registradas en la estación a lo largo de los primeros 28 días de marzo de 2026.

<sup>1</sup><https://opendata.aemet.es/centrodedescargas/productosAEMET?>



Como se dispone de 28 observaciones, se aplica la clásica división 80 %-20 % para entrenamiento y test, de forma que se entrenará con los 23 primeros datos y se harán predicciones con los 5 últimos.

## ARIMA

Como ya se comentó antes, uno de los objetivos será comparar el desempeño de los modelos FTS propuestos con dos modelos ARIMA, uno aplicado a cada extremo. Es importante recalcar que esta aplicación del ARIMA parte con un grave problema: podría suceder que las predicciones del extremo inferior fuesen mayores que las del superior, de manera que no se obtendría un intervalo. Con las FTS intervalares esto no puede suceder, pues ya trabaja con ese formalismo en lugar de centrarse en los extremos independientemente.

Se procede de todas formas a aplicar ARIMA. Comenzando con la serie de extremos superiores, el modelo que a priori obtendría un mejor desempeño sería un ARIMA(0,0,1), es decir, un MA(1). Si se procede al análisis de los residuos, se obtiene lo siguiente:




Figura 5.5: Análisis de los residuos del ARIMA del extremo superior.

Se aprecia ya algún aspecto problemático, como la falta de normalidad en la distribución de los residuos, sustentado además por un p-valor en el test de Shapiro-Wilk de 0.00992. Además, la homocedasticidad no es del todo evidente, pues se observan variaciones importantes en los residuos, sobre todo al principio de la serie. Sin embargo,

el modelo no muestra rasgos significativos de sesgo, ni en la gráfica superior ni en el test de Wilcoxon, y el gráfico ACF parece indicar que no están autocorrelacionados. En global, este análisis obliga a tratar con bastante cautela las predicciones que realice este modelo.

En cuanto al extremo inferior, el modelo con mejor desempeño es un ARIMA (2,0,0), o equivalentemente, un AR(2). Al igual que antes, la serie parece no requerir diferenciación para obtener estacionariedad. El análisis de los residuos es el siguiente:




Figura 5.6: Análisis de los residuos del ARIMA del extremo inferior.

No se observan sesgo ni autocorrelaciones importantes. Tampoco se puede rechazar la normalidad, pues ni el gráfico ni los tests de Shapiro-Wilk y Jarque-Bera encuentran diferencias significativas. La homocedasticidad sí que podría dar problemas, aunque parece que en menor medida que en el caso anterior.

En conclusión, se tienen dos modelos ARIMA distintos, uno para temperaturas máximas y otro para mínimas, con unos residuos ligeramente problemáticos. Esto ya de por sí haría plantearse otras alternativas, como una transformación de los datos, o incluso un cambio de modelo. Sin embargo, se tomarán como válidas sus predicciones para su posterior comparación con las de las FTS.

## FTS

Se procede a continuación a poner en práctica los métodos de FTS intervalares desarrollados en esta sección. Como se explicó, lo primero que hay que hacer es definir

el universo de discurso. Para ello, se aplicó lo siguiente:

$$U = [T_{\min} - D, T_{\max} + D], \quad D = 0.2 \cdot (T_{\max} - T_{\min}) \quad (5.4)$$

Así, el universo de discurso queda:  $U = [-0.74, 25.44]$ . Con esto se da pie a que aparezcan valores fuera del rango marcado por los datos.

A continuación, es necesario definir los conjuntos difusos  $A_j$ . Encontrar la partición óptima que maximice el rendimiento del modelo sería un trabajo bastante duro y prolongado, pues existen en la literatura multitud de métodos inspirados en distintas ideas. Destacan aquellas basadas en teoría de la información y la entropía [8] o el clustering [9]. En este trabajo se optó por un procedimiento mucho más sencillo. Se escogieron intervalos de igual amplitud, siendo esta un valor relativamente cercano a la media de la longitud de las observaciones del entrenamiento, y se distribuyeron según los histogramas de los datos. En este conjunto concreto, las temperaturas máximas y mínimas pueden verse en la figura 5.7.




Figura 5.7: Histogramas de las temperaturas máximas y mínimas.

Esto, sumado a que la amplitud media de los intervalos es 8.5, favoreció la elección de la siguiente partición:

- $A_1 = [-0.74, 10]$ ,
- $A_2 = [5, 13]$ ,
- $A_3 = [6, 14]$ ,
- $A_4 = [7, 15]$ ,
- $A_5 = [8, 16]$ ,
- $A_6 = [11, 19]$ ,
- $A_7 = [14, 25.44]$ .

Una vez ya definidos, se normalizan tanto los datos como los conjuntos  $A_j$ , para que así las similitudes puedan trabajar con ellos. Se escoge la incrustación y si la similitud es  $\sqcup$ -agregada o no (se recuerda que como función de agregación se utiliza la media aritmética), y se procede a aplicar el algoritmo descrito previamente.

## Resultados

A continuación se presentan los resultados, tanto del ARIMA como de la FTS, para las distintas métricas empleadas. Conviene aclarar que, en las tablas relacionadas con la FTS, las celdas tendrán un color verde si mejoran la métrica del ARIMA, y rojo si no lo hacen.

| ARIMA    |          |          |          |
|----------|----------|----------|----------|
| RSME     |          | MAPE     |          |
| EXT_INF  | EXT_SUP  | EXT_INF  | EXT_SUP  |
| 2.593618 | 4.118525 | 55.65928 | 31.64707 |

Figura 5.8: Resultados del ARIMA.

|              |    | CHEN    |         |          |          | CHENG   |         |          |          | SIM 1   |         |          |          | SIM 2   |         |          |          | SIM 3   |         |          |          |
|--------------|----|---------|---------|----------|----------|---------|---------|----------|----------|---------|---------|----------|----------|---------|---------|----------|----------|---------|---------|----------|----------|
|              |    | RSME    |         | MAPE     |          | RSME    |         | MAPE     |          | RSME    |         | MAPE     |          | RSME    |         | MAPE     |          | RSME    |         | MAPE     |          |
| INCRUSTACIÓN | □  | EXT_INF | EXT_SUP | EXT_INF  | EXT_SUP  | EXT_INF | EXT_SUP | EXT_INF  | EXT_SUP  | EXT_INF | EXT_SUP | EXT_INF  | EXT_SUP  | EXT_INF | EXT_SUP | EXT_INF  | EXT_SUP  | EXT_INF | EXT_SUP | EXT_INF  | EXT_SUP  |
| Longitud     | No | 2.68259 | 3.53596 | 54.20855 | 23.15450 | 2.88104 | 3.48876 | 58.92467 | 23.29235 | 1.92939 | 3.10597 | 40.03924 | 20.50001 | 1.97752 | 3.89403 | 41.10368 | 26.64717 | 1.97908 | 3.88141 | 41.28653 | 26.61449 |
| Longitud     | Si | 2.68259 | 3.53596 | 54.20855 | 23.15450 | 2.88104 | 3.48876 | 58.92467 | 23.29235 | 2.73617 | 3.41549 | 52.44533 | 24.07320 | 2.81600 | 3.84845 | 58.09592 | 27.93108 | 2.76255 | 3.49703 | 55.41070 | 24.13092 |
| Lukasiewicz  | No | 2.65292 | 4.03708 | 57.24584 | 31.06810 | 2.84674 | 4.03708 | 61.73858 | 31.06810 | 2.57023 | 3.93743 | 55.30424 | 30.13623 | 2.71298 | 3.99372 | 58.64525 | 30.66193 | 2.71745 | 4.00205 | 58.74916 | 30.74024 |
| Lukasiewicz  | Si | 2.65292 | 4.03708 | 57.24584 | 31.06810 | 2.84674 | 4.03708 | 61.73858 | 31.06810 | 2.57023 | 3.93743 | 55.30424 | 30.13623 | 2.71298 | 3.99372 | 58.64525 | 30.66193 | 2.71745 | 4.00205 | 58.74916 | 30.74024 |
| Godel        | No | 3.10934 | 4.35982 | 67.72890 | 33.91398 | 3.70034 | 4.66348 | 80.88549 | 36.24965 | 4.42063 | 6.19895 | 96.21664 | 48.53294 | 4.03465 | 5.41117 | 88.26752 | 42.24618 | 3.99298 | 5.32823 | 87.37430 | 41.58732 |
| Godel        | Si | 3.10934 | 4.35982 | 67.72890 | 33.91398 | 3.70034 | 4.66348 | 80.88549 | 36.24965 | 4.42063 | 6.19895 | 96.21664 | 48.53294 | 4.03465 | 5.41117 | 88.26752 | 42.24618 | 3.99298 | 5.32823 | 87.37430 | 41.58732 |
| Goguen       | No | 3.10934 | 4.35982 | 67.72890 | 33.91398 | 3.42040 | 4.55298 | 74.71760 | 35.49502 | 3.02777 | 4.25763 | 65.88138 | 33.03303 | 3.23784 | 4.42592 | 70.63428 | 34.45901 | 3.28099 | 4.47425 | 71.60417 | 34.85741 |
| Goguen       | Si | 3.10934 | 4.35982 | 67.72890 | 33.91398 | 3.42040 | 4.55298 | 74.71760 | 35.49502 | 3.02777 | 4.25763 | 65.88138 | 33.03303 | 3.23784 | 4.42592 | 70.63428 | 34.45901 | 3.28099 | 4.47425 | 71.60417 | 34.85741 |
| Fodor        | No | 1.70138 | 3.02167 | 36.57393 | 20.80321 | 3.27798 | 4.49800 | 71.53005 | 35.05233 | 1.76962 | 3.01394 | 37.74833 | 20.81127 | 2.79029 | 4.08041 | 60.44122 | 31.45961 | 2.85481 | 4.13462 | 61.92717 | 31.96095 |
| Fodor        | Si | 1.70138 | 3.02167 | 36.57393 | 20.80321 | 3.27798 | 4.49800 | 71.53005 | 35.05233 | 1.76962 | 3.01394 | 37.74833 | 20.81127 | 2.79029 | 4.08041 | 60.44122 | 31.45961 | 2.85481 | 4.13462 | 61.92717 | 31.96095 |
| Exponencial  | No | 3.10934 | 4.24843 | 67.72890 | 32.96535 | 2.89690 | 3.99067 | 32.89056 | 30.63027 | 3.36932 | 4.47699 | 73.58762 | 34.87853 | 3.11173 | 4.19976 | 67.78564 | 32.53315 | 3.05949 | 4.15294 | 66.60196 | 32.11873 |
| Exponencial  | Si | 3.10934 | 4.24843 | 67.72890 | 32.96535 | 2.89690 | 3.99067 | 32.89056 | 30.63027 | 3.36932 | 4.47699 | 73.58762 | 34.87853 | 3.11173 | 4.19976 | 67.78564 | 32.53315 | 3.05949 | 4.15294 | 66.60196 | 32.11873 |

Figura 5.9: Resultados detallados de errores (RMSE y MAPE).

| INCRUSTACIÓN | □  | ARIMA    | CHEN      | CHENG    | SIM 1     | SIM 2    | SIM3     |
|--------------|----|----------|-----------|----------|-----------|----------|----------|
| Longitud     | No | 0.573343 | 0.6169407 | 0.609688 | 0.6438606 | 0.611411 | 0.610969 |
| Longitud     | Si |          | 0.6169407 | 0.609688 | 0.6385068 | 0.586781 | 0.61273  |
| Lukasiewicz  | No |          | 0.5775262 | 0.571253 | 0.5825498 | 0.576516 | 0.576184 |
| Lukasiewicz  | Si |          | 0.5775262 | 0.571253 | 0.5825498 | 0.576516 | 0.576184 |
| Godel        | No |          | 0.5573965 | 0.541019 | 0.4943261 | 0.516724 | 0.519255 |
| Godel        | Si |          | 0.5573965 | 0.541019 | 0.4943261 | 0.516724 | 0.519255 |
| Goguen       | No |          | 0.5573965 | 0.545388 | 0.5612458 | 0.552195 | 0.550211 |
| Goguen       | Si |          | 0.5573965 | 0.545388 | 0.5612458 | 0.552195 | 0.550211 |
| Fodor        | No |          | 0.6348427 | 0.550368 | 0.635124  | 0.572212 | 0.569188 |
| Fodor        | Si |          | 0.6348427 | 0.550368 | 0.635124  | 0.572212 | 0.569188 |
| Exponencial  | No |          | 0.5590903 | 0.570625 | 0.5472441 | 0.559722 | 0.562227 |
| Exponencial  | Si |          | 0.5590903 | 0.570625 | 0.5472441 | 0.559722 | 0.562227 |

Figura 5.10: Resultados de la similitud media.

Se aprecian diversas situaciones. Existen casos en los que la FTS mejora la predicción de ambos extremos, otros en los que se mejora uno y el otro no, y otros donde ARIMA sigue siendo superior. En cuanto a la métrica de la similitud media, destacan por su rendimiento la incrustación basada en la amplitud, la de Łukasiewicz y la de Fodor en algunos casos. Si hablamos de los métodos de defuzzificación, parecen emerger dos de ellos como los más adecuados para este problema: Chen y SIM 1 (ponderación por similitud). Finalmente, se observa que el factor de que la similitud sea  $\sqcup$ -agregada no influye demasiado en la similitud. Solo varía en la incrustación basada en la amplitud, donde las no  $\sqcup$ -agregadas poseen un desempeño algo mayor para SIM 1 y SIM 2, y ligeramente menor en SIM 3. Sin embargo, en ambos casos se supera en rendimiento al ARIMA.

Con todo ello, la mejor elección parece ser el método SIM 1, utilizando la incrustación basada en la amplitud sin la  $\sqcup$ -agregación. Para este conjunto de datos, esta configuración ofrece un rendimiento superior al ARIMA considerado. Además, presenta la ventaja de no requerir hipótesis sobre los residuos y de devolver siempre intervalos consistentes. En concreto, se aumenta la similitud entre la predicción y el test desde 0.57 en ARIMA hasta un 0.64, lo que supone una mejora relativa cercana al 12 %. En cuanto a los errores en los extremos, el RMSE disminuye  $0.6^{\circ}\text{C}$  en el extremo inferior y  $1^{\circ}\text{C}$  en el extremo superior, mientras que el MAPE se reduce 15 y 11 puntos respectivamente.

### 5.2.2. Ejemplo 2: predicción del precio diario de la electricidad

El segundo conjunto de datos utilizado para evaluar la idoneidad de los métodos propuestos consiste en los precios máximos y mínimos de la electricidad en el mercado mayorista de España. Dichos datos fueron obtenidos gracias a ESIOs<sup>2</sup>, la plataforma digital oficial de Red Eléctrica Española que gestiona y publica toda la información sobre el sistema y mercado eléctrico español. En concreto, la serie utilizada en este trabajo toma valores desde el 1 de enero de 2023 hasta el 21 de enero del 2026 (fecha

<sup>2</sup><https://www.esios.ree.es/es/analisis>

en la que se extrajeron los datos), lo que resulta en un total de 1118 observaciones. A la hora de generar los intervalos, para cada día se tomaron los precios registrados por hora, y entre ellos se seleccionó el mínimo y máximo. De este modo se obtuvo un intervalo diario del precio del  $MW/h$  y, por tanto, una serie intervalar. Gráficamente, las series poseen el siguiente aspecto:




Figura 5.11: Precio de la electricidad en el mercado mayorista desde el 1/1/2023 hasta el 21/1/2026.

Observando la serie, se aprecia que en determinados momentos, el precio mínimo toma valores negativos. Esto no es un problema de los datos, sino que es un mecanismo de ajuste para responder al desequilibrio producido cuando se genera más electricidad de la necesaria, debido a factores como baja demanda o exceso de producción de las renovables. Cabe destacar que estos precios, como ya se dijo previamente, pertenecen al mercado mayorista. Es decir, no se corresponden con lo que pagan los consumidores, ya que al añadir costes adicionales (impuestos, peajes, etc) los precios finales resultan positivos [21].

A continuación, se procedería a la separación entre entrenamiento y prueba. Siguiendo la metodología clásica, se aplicaría la regla del 80 % – 20 %, como en el primer ejemplo. Esto implicaría un conjunto de entrenamiento con 895 observaciones, y un conjunto de prueba con 223. Sin embargo, durante la elaboración de este trabajo se observó que, a partir del quinto o sexto día, las predicciones tendían a estabilizarse en

torno a un valor casi constante: en el caso de ARIMA, alrededor del valor medio de la serie; en el caso de las FTS, alrededor del conjunto  $A_j$  más frecuente en los FLRG.

Aunque las métricas no diesen valores especialmente malos, es razonable pensar que carece de sentido tener en cuenta una predicción cuyo valor es siempre el mismo, independientemente del tiempo. Es por ello que, para este ejemplo, se decidió evaluar los modelos a muy corto plazo, en concreto, a tres días vista. Dicha elección viene sustentada, además, por cómo se trabaja en la predicción del precio del mercado eléctrico. Factores como la alta volatilidad o la gran cantidad de variables externas que influyen en él (y que estos modelos simples no son capaces de tener en cuenta) hacen que estos métodos basados en series temporales sean realmente útiles a corto plazo, mientras que para aumentar el horizonte de predicción es necesario recurrir a otras técnicas como simulación [1, 18].

## ARIMA

Al igual que en el primer ejemplo, se busca un modelo ARIMA para las series temporales de los extremos de los intervalos. Comenzando con los extremos superiores, el adecuado es un ARIMA (3,1,1), es decir, fue necesaria una diferenciación para lograr la estacionariedad. El análisis gráfico de los residuos puede verse en la figura 5.12.




Figura 5.12: Análisis de los residuos del ARIMA del extremo superior.

A primera vista, parece que son insesgados y la homocedasticidad se verifica. En cuanto a la normalidad, tanto los test de Shapiro-Wilk como de Jarque-Bera la rechazan (posiblemente porque, al ser tantos datos, la mínima diferencia respecto a la distribución ideal la considera significativa). Sin embargo, el histograma no muestra



desviaciones extremas respecto a una forma aproximadamente normal, por lo que el principal problema del modelo parece estar más relacionado con la autocorrelación que con la forma marginal de los residuos. Ahora bien, se encuentra un problema considerable en el gráfico ACF, pues existen una gran cantidad de coeficientes que salen del intervalo de confianza, lo que parece indicar autocorrelación y, por tanto, cuestionar la validez de dicho modelo.

En cuanto al extremo inferior, el modelo con mejor desempeño es un ARIMA (1,1,2), es decir, se vuelve a requerir una diferenciación. El análisis de los residuos se muestra en la figura 5.13.




Figura 5.13: Análisis de los residuos del ARIMA del extremo inferior.

Al igual que antes, parece estar garantizada la homocedasticidad y la ausencia de sesgo, además de que la distribución se asemeja a la función de densidad de una normal. Sin embargo, vuelve a aparecer el problema de la autocorrelación, pues una gran multitud de coeficientes exceden el intervalo de confianza.

Recapitulando, se dispone de dos modelos ARIMA, uno para precios máximos y otro para precios mínimos, que muestran sobre todo un exceso de autocorrelación en los residuos. Como ya se dijo en el ejemplo anterior, que el ARIMA a priori más idóneo tenga estos problemas sería un argumento considerable para explorar otras alternativas. Sin embargo, manteniendo presentes estas limitaciones, se conservarán sus predicciones como referencia comparativa.

## FTS

Se aplican ahora los métodos FTS. Primeramente, se define el universo de discurso siguiendo (5.4). Sin embargo, a diferencia del caso anterior, esta serie toma valores mucho más amplios (desde  $-15 \text{ MW/h}$  hasta  $240 \text{ MW/h}$ ), y esos extremos están marcados por periodos muy anómalos que parecen prácticamente imposibles de alcanzar, sobre todo en pronósticos a tan corto plazo como en este caso. Probando para diferentes valores de  $r$ , y en base al razonamiento anterior, se optó por tomar  $r = 0.01$  en lugar de tomar  $r = 0.2$ , quedando el universo de discurso definido por  $U = [-17.55, 242.55]$ .

En cuanto a la definición de los conjuntos difusos, se decidió mantener la estrategia del caso anterior: que su longitud fuese relativamente parecida a la amplitud media de los intervalos de la serie (se escogió que tuviesen amplitud 60), y que se basasen en los histogramas de los precios máximos y mínimos, que se muestran en la figura 5.14.




Figura 5.14: Histogramas de los precios mínimos y máximos.

La partición queda por tanto definida de la siguiente manera:

- $A_1 = [-17.55, 40]$ ,
- $A_2 = [0, 60]$ ,
- $A_3 = [5, 65]$ ,
- $A_4 = [10, 70]$ ,
- $A_5 = [20, 80]$ ,
- $A_6 = [30, 90]$ ,
- $A_7 = [40, 100]$ ,
- $A_8 = [45, 105]$ ,
- $A_9 = [50, 110]$ ,
- $A_{10} = [55, 115]$ ,
- $A_{11} = [60, 120]$ ,
- $A_{12} = [65, 125]$ ,
- $A_{13} = [70, 130]$ ,
- $A_{14} = [80, 140]$ ,
- $A_{15} = [90, 150]$ ,
- $A_{16} = [110, 170]$ ,
- $A_{17} = [130, 190]$ ,
- $A_{18} = [150, 210]$ ,
- $A_{19} = [170, 230]$ ,
- $A_{20} = [190, 242.55]$ .

## Resultados

Con todo esto, se procede a la normalización de los datos y los conjuntos difusos, y a la aplicación del algoritmo. Los resultados del ARIMA y FTS para las distintas métricas se muestran en la siguiente página, siguiendo el mismo código de colores que en el ejemplo anterior:

| ARIMA    |          |          |          |
|----------|----------|----------|----------|
| RSME     |          | MAPE     |          |
| EXT_INF  | EXT_SUP  | EXT_INF  | EXT_SUP  |
| 13.44659 | 27.27756 | 14.24946 | 20.66429 |

Figura 5.15: Resultados del ARIMA.

|              |    | CHEN     |          |          |          | CHENG    |          |          |           | SIM 1    |           |           |           | SIM 2    |           |          |           | SIM 3    |           |          |          |
|--------------|----|----------|----------|----------|----------|----------|----------|----------|-----------|----------|-----------|-----------|-----------|----------|-----------|----------|-----------|----------|-----------|----------|----------|
|              |    | RSME     |          | MAPE     |          | RSME     |          | MAPE     |           | RSME     |           | MAPE      |           | RSME     |           | MAPE     |           | RSME     |           | MAPE     |          |
| INCRUSTACIÓN | U  | EXT_INF  | EXT_SUP  | EXT_INF  | EXT_SUP  | EXT_INF  | EXT_SUP  | EXT_INF  | EXT_SUP   | EXT_INF  | EXT_SUP   | EXT_INF   | EXT_SUP   | EXT_INF  | EXT_SUP   | EXT_INF  | EXT_SUP   | EXT_INF  | EXT_SUP   | EXT_INF  | EXT_SUP  |
| Longitud     | No | 29.69167 | 32.4443  | 36.0508  | 14.36964 | 25.27919 | 44.12930 | 29.06988 | 34.69348  | 5.297101 | 26.189238 | 6.242012  | 19.637186 | 2.800628 | 23.703817 | 3.444267 | 18.198814 | 23.53663 | 42.81052  | 26.41547 | 33.76709 |
| Longitud     | Si | 29.69167 | 32.4443  | 36.0508  | 14.36964 | 25.27919 | 44.12930 | 29.06988 | 34.69348  | 22.37272 | 28.04102  | 26.5861   | 14.04606  | 9.284594 | 22.034957 | 11.27948 | 13.7448   | 8.158542 | 20.753466 | 10.16349 | 13.406   |
| Lukasiewicz  | No | 22.09439 | 31.59816 | 21.56939 | 19.22697 | 25.92769 | 44.6157  | 30.05101 | 35.02089  | 17.55351 | 28.26225  | 19.11936  | 14.60271  | 8.110535 | 22.792617 | 8.925763 | 14.921209 | 6.449674 | 21.106746 | 7.17532  | 14.45523 |
| Lukasiewicz  | Si | 22.09439 | 31.59816 | 21.56939 | 19.22697 | 25.92769 | 44.6157  | 30.05101 | 35.02089  | 18.17091 | 27.63965  | 20.8507   | 13.47498  | 10.91283 | 21.76116  | 12.28225 | 12.70315  | 9.884799 | 19.925502 | 10.72713 | 12.10755 |
| Godel        | No | 34.13798 | 40.56656 | 36.21848 | 22.19618 | 20.69476 | 40.76056 | 23.3377  | 32.22079  | 6.751219 | 28.594488 | 8.045124  | 22.034922 | 18.09442 | 38.71943  | 20.84975 | 30.48815  | 24.61548 | 44.0291   | 27.27946 | 34.83352 |
| Godel        | Si | 34.13798 | 40.56656 | 36.21848 | 22.19618 | 20.69476 | 40.76056 | 23.3377  | 32.22079  | 22.54076 | 29.5652   | 26.02651  | 15.08356  | 12.84203 | 23.60846  | 15.11386 | 12.89229  | 12.42636 | 22.59583  | 14.95132 | 12.37055 |
| Goguen       | No | 28.01482 | 32.4294  | 32.31434 | 17.12776 | 23.82777 | 43.05054 | 26.82645 | 33.944482 | 11.64222 | 21.64934  | 13.75638  | 12.17667  | 7.428816 | 19.20407  | 9.19677  | 12.78306  | 11.5013  | 31.72221  | 12.77911 | 25.41901 |
| Goguen       | Si | 28.01482 | 32.4294  | 32.31434 | 17.12776 | 23.82777 | 43.05054 | 26.82645 | 33.944482 | 16.69432 | 27.27828  | 18.07496  | 14.76255  | 11.67779 | 20.60848  | 14.3451  | 11.43369  | 10.88995 | 19.56681  | 13.5842  | 11.23498 |
| Fodor        | No | 11.86505 | 17.20404 | 14.22378 | 9.40643  | 27.00508 | 45.43006 | 31.65694 | 35.55681  | 4.910209 | 21.816765 | 4.426707  | 15.725453 | 23.17295 | 42.49318  | 25.881   | 33.52174  | 23.99942 | 42.86863  | 26.68477 | 33.79336 |
| Fodor        | Si | 13.71776 | 16.27159 | 16.5957  | 7.80657  | 27.00508 | 45.43006 | 31.65694 | 35.55681  | 12.5588  | 15.9293   | 15.056146 | 8.407998  | 23.17295 | 42.49318  | 25.9181  | 33.52174  | 23.99942 | 42.86863  | 26.68477 | 33.79336 |
| Exponencial  | No | 33.54722 | 39.32871 | 36.41238 | 21.27221 | 22.08317 | 41.77016 | 24.43591 | 33.00755  | 8.875427 | 29.941    | 10.49189  | 23.82498  | 20.77294 | 40.73198  | 23.25898 | 32.19117  | 24.91203 | 43.82621  | 28.55271 | 34.47434 |
| Exponencial  | Si | 33.54722 | 39.32871 | 36.41238 | 21.27221 | 22.08317 | 41.77016 | 24.43591 | 33.00755  | 22.10535 | 28.55105  | 25.82762  | 14.67724  | 13.19425 | 21.9643   | 16.23895 | 11.42623  | 12.75572 | 21.1472   | 15.78418 | 11.13711 |

Figura 5.16: Resultados detallados de errores (RMSE y MAPE).

| INCRUSTACIÓN | U  | ARIMA     | CHEN      | CHENG     | SIM 1     | SIM 2     | SIM3      |
|--------------|----|-----------|-----------|-----------|-----------|-----------|-----------|
| Longitud     | No | 0.6207757 | 0.5571885 | 0.5390184 | 0.6393697 | 0.65766   | 0.5466635 |
| Longitud     | Si |           | 0.5571885 | 0.5390184 | 0.5883572 | 0.6480694 | 0.6544208 |
| Lukasiewicz  | No |           | 0.5785668 | 0.536326  | 0.6153241 | 0.6501804 | 0.6600482 |
| Lukasiewicz  | Si |           | 0.5785668 | 0.536326  | 0.6153241 | 0.6504222 | 0.6603008 |
| Godel        | No |           | 0.5264487 | 0.5539989 | 0.6140193 | 0.5621416 | 0.541744  |
| Godel        | Si |           | 0.5264487 | 0.5539989 | 0.5857366 | 0.6388948 | 0.6422735 |
| Goguen       | No |           | 0.5554381 | 0.5453712 | 0.6477153 | 0.6623647 | 0.5902698 |
| Goguen       | Si |           | 0.5554381 | 0.5453712 | 0.6166531 | 0.6498193 | 0.6544915 |
| Fodor        | No |           | 0.6629192 | 0.5320172 | 0.664116  | 0.5484093 | 0.5461138 |
| Fodor        | Si |           | 0.6629192 | 0.5320172 | 0.664116  | 0.5484093 | 0.5461138 |
| Exponencial  | No |           | 0.5290442 | 0.5519122 | 0.6000288 | 0.5551126 | 0.540604  |
| Exponencial  | Si |           | 0.5290442 | 0.5519122 | 0.5877604 | 0.6428421 | 0.6461125 |

Figura 5.17: Resultados de la similitud media.

Atendiendo a todas las métricas, se observa un patrón claro: los métodos Chen y Cheng no mejoran el desempeño del ARIMA. El método SIM 1 sí que ya empieza a mostrar un mejor funcionamiento, sobre todo en los casos sin  $\sqcup$ -agregación, pero en general tampoco lo supera. Donde sí destacan las FTS es con los métodos SIM 2 y SIM 3, donde se aprecia una mejora general, tanto en el RMSE y MAPE de los extremos, como en la similitud media. Todas las incrustaciones (salvo la de Fodor) mejoran al ARIMA, y destaca sobre todo el gran rendimiento de las similitudes  $\sqcup$ -agregadas, pues para estos dos métodos suelen mejorar, en general, a las no  $\sqcup$ -agregadas. En algunos casos, como SIM 3 con incrustación basada en amplitud, o SIM 2 y SIM 3 con incrustación exponencial, se consigue incluso pasar de empeorar el ARIMA a mejorarlo, lo cual indica el potencial que tienen estas extensiones para determinados conjuntos de datos, como ocurre en este caso.

Para acabar con este ejemplo, se plantea una última cuestión. En problemas de regresión y clasificación, se sigue un procedimiento similar al de series temporales, en el sentido de que también se realiza una división del conjunto de datos en entrenamiento y prueba. Ahora bien, al evaluar el modelo, siempre surge la duda de si dicho desempeño está influenciado por cómo se dividieron los datos. Es decir, podría ocurrir que el azar haya determinado que dicha partición sobrestime la capacidad predictiva del modelo, de forma que otra partición diese resultados mucho peores, o viceversa. Para atajar esto existen diversas propuestas, una de las más populares es la validación cruzada o *k-fold cross validation*, que consiste en realizar  $k$  particiones distintas del conjunto de datos, evaluar el modelo para cada una de ellas y finalmente hacer un promedio del resultado de las métricas. De esta forma se obtiene una noción mucho más robusta de su desempeño [4].

En el caso de series temporales, surge una problemática similar, pues podría existir la posibilidad de que el rendimiento del modelo esté fuertemente influenciado por el periodo de tiempo en el que se está evaluando. Existe entonces una técnica, conocida como validación cruzada para series temporales o *time series cross validation*. El concepto es muy sencillo, se ilustra con la figura 5.18.




Figura 5.18: Esquema gráfico del *time series cross validation* [12].

El procedimiento es el siguiente. Se comienza entrenando con un número determinado de datos, y se predice el horizonte seleccionado (en el ejemplo tratado, tendría longitud 3). Se evalúa el modelo y se almacena el resultado de las métricas. Posteriormente, se incluyen en el entrenamiento los valores reales de la serie de los días que predijimos, y se entrena con este nuevo conjunto. Se predicen los tres siguientes y se vuelven a guardar las métricas resultantes. Se continúa con este proceso hasta el final de la serie, y para evaluar el rendimiento global se promedian las métricas de cada iteración. De esta forma se reduce la influencia que podría tener la elección concreta del periodo de prueba [12].

El número de iteraciones (conocidas como *folds*) no es fijo, y depende del conjunto de datos y el coste computacional que se pueda asumir. En el ejemplo tratado, como tenemos datos desde el 1 de enero de 2023 hasta el 21 de enero del 2026, se decidió poner el primer origen de predicción el 1 de diciembre de 2025, y de ahí ir aumentando de 3 en 3. En total se obtuvieron 17 *folds*, que no implica un coste computacional excesivamente alto y permite, sin reducir demasiado el conjunto de entrenamiento, obtener una idea de la robustez de los modelos.

En este caso, para no hacerlo muy engorroso, se optó por utilizar como única métrica la similitud media. Los resultados pueden verse en la figura 5.19.

| INCRUSTACIÓN | $\sqcup$ | ARIMA     | CHEN      | CHENG     | SIM 1     | SIM 2     | SIM3      |
|--------------|----------|-----------|-----------|-----------|-----------|-----------|-----------|
| Longitud     | No       | 0.6439046 | 0.6470853 | 0.6249462 | 0.6522682 | 0.6398936 | 0.6386964 |
| Longitud     | Si       |           | 0.6470853 | 0.6249462 | 0.6518249 | 0.6435314 | 0.6439198 |
| Lukasiewicz  | No       |           | 0.6489647 | 0.6466933 | 0.6559087 | 0.6559192 | 0.6561354 |
| Lukasiewicz  | Si       |           | 0.6489647 | 0.6466933 | 0.6539095 | 0.6543569 | 0.6580254 |
| Godel        | No       |           | 0.6396165 | 0.6358696 | 0.6508028 | 0.6475145 | 0.6387333 |
| Godel        | Si       |           | 0.6396165 | 0.6358696 | 0.6465233 | 0.6507268 | 0.6514134 |
| Goguen       | No       |           | 0.6485783 | 0.6343718 | 0.6572898 | 0.6515532 | 0.6484101 |
| Goguen       | Si       |           | 0.6485783 | 0.6343718 | 0.6528439 | 0.6486065 | 0.6489227 |
| Fodor        | No       |           | 0.6258768 | 0.5739281 | 0.6375641 | 0.6129444 | 0.6134134 |
| Fodor        | Si       |           | 0.6267919 | 0.5633272 | 0.6220206 | 0.5843139 | 0.5836847 |
| Exponencial  | No       |           | 0.6407823 | 0.6364877 | 0.6533808 | 0.6418201 | 0.6406565 |
| Exponencial  | Si       |           | 0.6407823 | 0.6364877 | 0.6489338 | 0.6495676 | 0.6502234 |

Figura 5.19: Resultados de las similitudes medias tras el *time series cross validation*.

Se observa como sobre todo los métodos SIM 1, SIM 2 y SIM 3 dan el mejor rendimiento (salvo Fodor, como ocurría anteriormente). Además, vuelve a apreciarse como las  $\sqcup$ -agregadas dan un rendimiento ligeramente mayor. Ahora bien, se puede notar que, cuando se mejora al ARIMA, se hace por un margen muy pequeño, muchas veces un 0.01, luego se podría considerar que el desempeño de ambos modelos es prácticamente el mismo. Sin embargo, un punto que juega a favor de las FTS es el siguiente: para cada *fold*, el modelo ARIMA utilizado cambia, pues es el que mejor se ajusta a los datos del entrenamiento. Sin embargo, el modelo FTS es siempre el mismo, no se cambiaron ni el universo de discurso ni los conjuntos difusos  $A_j$ . Esto ya de por sí muestra una gran robustez, pues es capaz de igualar el rendimiento de un modelo cuyos parámetros cambiaron en cada *fold* sin necesidad de alterar los suyos. Pero es más, si se hiciese una elección más óptima de los  $A_j$ , véase mediante clustering, y dicha elección fuese distinta según el *fold*, posiblemente su desempeño mejorase más, ampliando su ventaja frente al ARIMA.

Recapitulando lo expuesto hasta el momento, se ha desarrollado un modelo de predicción de series intervalares, extendiendo los métodos tradicionales de FTS y empleando las similitudes basadas en incrustaciones desarrolladas en la primera parte del trabajo. Para comprobar su validez, se aplicaron a dos conjuntos de datos, uno de temperaturas y otro de precios de la electricidad, y se comparó su desempeño con el de un ARIMA aplicado a cada extremo de los intervalos. Además, aprovechando dichas similitudes, se propusieron tres métodos nuevos de defuzzificación (SIM 1, SIM 2 y

SIM 3) que involucraban estos operadores, y una nueva métrica (la similitud media) que permitía comparar globalmente los intervalos reales y de predicción.

Metodológicamente, los modelos FTS parten con la ventaja de trabajar de forma natural con intervalos, mientras que los ARIMA en los extremos pueden dar lugar a incongruencias como que el extremo superior fuese menor que el inferior. Además, los modelos FTS no descansan sobre hipótesis de ruido blanco en los residuos, por lo que evitan una parte importante del diagnóstico exigido por los modelos ARIMA. Aun así, su desempeño debe evaluarse empíricamente mediante las métricas correspondientes.

Los resultados del método fueron bastante prometedores, pues gracias a la gran variedad de similitudes de las que se disponen se pudo encontrar, en ambos ejemplos, alguna configuración FTS que igualaba o mejoraba al ARIMA considerado en las métricas empleadas. También es importante resaltar que, en general, tanto Chen y Cheng son superados por SIM 1, SIM 2 y SIM 3, y que los modelos FTS todavía presentan margen de mejora mediante la optimización de procesos como la partición del universo de discurso. Finalmente, para los datos de precios de la electricidad se decidió poner a prueba la robustez del método aplicando *time series cross validation*. El resultado fue que los modelos FTS, sin modificar ninguno de sus parámetros, igualaban e incluso superaban a un ARIMA cuyos parámetros en cada *fold* eran los óptimos, mostrando el potencial de estos métodos para series con fuerte volatilidad.



# Capítulo 6

## Conclusiones

A lo largo de este trabajo se ha llevado a cabo un desarrollo teórico de las incrustaciones y de las similitudes obtenidas a partir de ellas, estudiando sus propiedades y algunas de sus limitaciones. Además, dichas herramientas se han puesto a prueba en un método de predicción de series temporales intervalares.

En primer lugar, se introdujo la idea de incrustación y se desarrolló formalmente este concepto. Se mostró cómo recoge los casos clásicos de la lógica booleana, al tiempo que permite describir situaciones intermedias. Se estudiaron dos tipos de incrustaciones según su origen: unas basadas en la amplitud de los intervalos y otras construidas a partir de funciones de implicación aplicadas a sus extremos. Además, para estas últimas fue posible establecer una relación de orden. En ambos casos se obtuvieron resultados coherentes, generalizando así la relación de contenido entre intervalos.

Posteriormente, se introdujo la definición general de los operadores de similitud, para más adelante dar un procedimiento sencillo para construirlos a partir de incrustaciones y t-normas/funciones de agregación simétricas y 1-estrictas. Tras ello, se puso de manifiesto la limitación que presentaban cuando los intervalos eran disjuntos, pues daban como resultado siempre 0 independientemente de cuál fuera el par. Para solucionarlo, se introdujo una nueva clase de similitudes, las conocidas como  $\sqcup$ -agregadas, que se valían del uso de la envolvente convexa. Fue posible demostrar, tanto para la incrustación basada en la amplitud de los intervalos como para las basadas en implicaciones, que estos nuevos operadores eran capaces de dar un valor no nulo aunque los intervalos fuesen disjuntos (siempre y cuando fuesen no degenerados). Así, se otorgaba más

similitud si la pareja estaba más próxima entre sí, a pesar de que tuviesen intersección vacía. Pero además, considerando implicaciones que verifican la propiedad de mínima falsedad e imponiendo a la función de agregación la condición de ser 0-estricta, se consiguieron resultados positivos incluso para intervalos degenerados. De esta forma, dicha nueva construcción permitió obtener nuevos operadores que cuantificasen la semejanza entre intervalos de manera no trivial, incluso para pares disjuntos o degenerados.

Finalmente, en el último capítulo se pusieron en práctica las similitudes desarrolladas, en el contexto de las series temporales intervalares. En concreto, se propuso una modificación del algoritmo FTS unipuntual, sustituyendo las funciones de membresía por las similitudes, y proponiendo nuevos métodos de defuzzificación a partir de ellas. Por otra parte, se comparó su desempeño con respecto a un modelo ARIMA aplicado a los extremos superior e inferior de la serie. Tras aplicar ambos métodos a un conjunto de datos de temperaturas y otro de precios de la electricidad, se pudo comprobar como siempre se encontraban casos en los que el algoritmo propuesto superaba al ARIMA, tanto para las métricas unipuntuales RMSE y MAPE como para la similitud media entre la predicción y el valor real. Además, el método FTS partía ya de la ventaja de que trabajaba de manera natural con intervalos, mientras que la aplicación separada de ARIMA a cada extremo podía producir predicciones que no definiesen un intervalo. En último lugar, se decidió poner a prueba la robustez de ambos métodos mediante validación cruzada para series temporales. Se concluyó que el algoritmo FTS era más robusto, pues igualaba o superaba mínimamente el desempeño del ARIMA sin cambiar ningún parámetro, mientras que este último se actualizaba en cada iteración.

Para concluir el trabajo, se exponen futuras líneas de investigación que podrían llevarse a cabo. Comenzando con el desarrollo teórico de las similitudes, destacaría extender todos los conceptos de los capítulos 3 y 4 a los llamados *Interval Valued Fuzzy Sets* (IVFS) [7, 25, 28], generalización de los conjuntos clásicos caracterizados porque la pertenencia de sus elementos se representa mediante un intervalo de  $\mathcal{L}([0, 1])$ , en lugar de la función característica propia de la lógica booleana. En cuanto a la segunda parte, destacaría la optimización del algoritmo, bien aplicando una mejor técnica de partición del universo de discurso o modificando la defuzzificación para que no tuviese en cuenta únicamente el instante inmediatamente anterior. Finalmente, sería interesante estudiar como combinar el método propuesto con ARIMA u otros modelos, de manera similar

a como hace Fuzzy ARIMA [5], pero en versión intervalar, lo que podría potenciar de manera considerable el pronóstico en series temporales de este tipo.

# Bibliografía

- [1] Aggarwal, S. K., Saini, L. M., and Kumar, A. (2009). Electricity price forecasting in deregulated markets: A review and evaluation. *International Journal of Electrical Power and Energy Systems*, 31(1):13–22.
- [2] Beliakov, G., Pradera, A., and Calvo, T. (2007). *Aggregation Functions: A Guide for Practitioners*, volume 221 of *Studies in Fuzziness and Soft Computing*. Springer.
- [3] Beliakov, G., Sola, H. B., and Calvo, T. (2016). *A Practical Guide to Averaging Functions*. Springer.
- [4] Bishop, C. (2006). *Pattern recognition and machine learning*, volume 4. Springer New York.
- [5] Bose, M. and Mali, K. (2019). Designing fuzzy time series forecasting models: A survey. *International Journal of Approximate Reasoning*, 111:78–99.
- [6] Bouchet, A., Díaz-Vázquez, S., Díaz, I., and Montes, S. (2024). Silimitudes basadas en medidas de incrustación. In *Actas del XXII Congreso Español sobre Tecnologías y Lógica Fuzzy (ESTYLF24)*, pages 326–331.
- [7] Bouchet, A., Sesma-Sara, M., Ochoa, G., Bustince, H., Montes, S., and Díaz, I. (2023). Measures of embedding for interval-valued fuzzy sets. *Fuzzy Sets and Systems*, 467:108505.
- [8] Cheng, C.-H., Chang, J.-R., and Yeh, C.-A. (2006). Entropy-based and trapezoid fuzzification-based fuzzy time series approaches for forecasting it project cost. *Technological Forecasting and Social Change*, 73(5):524–542.

- [9] Cheng, C.-H., Cheng, G.-W., and Wang, J.-W. (2008). Multi-attribute fuzzy time series method based on fuzzy clustering. *Expert Systems with Applications*, 34(2):1235–1242.
- [10] Dice, L. (1945). Measures of the amount of ecologic association between species. *Ecology*, 26(3):297–302.
- [11] Grabisch, M., Marichal, J.-L., lu Radko Mesiar, and Pap, E. (2008). "aggregation functions", cambridge university press. *2008 6th International Symposium on Intelligent Systems and Informatics*, pages 1–7.
- [12] Hyndman, R. J. and Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts.
- [13] Jaccard, P. (1908). Nouvelles recherches sur la distribution florale. *Bull. Soc. Vaud. Sci. Nat.*, 44:223–270.
- [14] Kabir, S., Wagner, C., Havens, T., and Anderson, D. (2020). A similarity measure based on bidirectional subethood for intervals. *IEEE Transactions on Fuzzy Systems*, PP:1–1.
- [15] Klement, E. P., Mesiar, R., and Pap, E. (2000). *Triangular Norms*. Trends in Logic. Springer.
- [16] Leonard, I. and Lewis, J. (2015). *Geometry of Convex Sets*.
- [17] Lucas, P., Orang, O., Silva, P., Mendes, E., and Guimarães, F. (2022). A tutorial on fuzzy time series forecasting models: Recent advances and challenges. *Learning and Nonlinear Models*, 19:29–50.
- [18] Martínez-Álvarez, F., Troncoso, A., Asencio-Cortés, G., and Riquelme, J. C. (2015). A survey on data mining techniques applied to electricity-related time series forecasting. *Energies*, 8(11):13162–13193.
- [19] Massanet, S., Mayor, G., Mesiar, R., and Torrens, J. (2013). On fuzzy implications: An axiomatic approach. *International Journal of Approximate Reasoning*, 54:1471–1482.

- [20] Nasr, M. (2023). Fuzzy time series forecasting: Chen, markov chain and cheng models. *Journal of Alexandria University for Administrative Sciences*, 60:33–45.
- [21] OCU (2024). Por primera vez el precio de la energía será negativo durante algunas horas. <https://www.ocu.org/organizacion/prensa/notas-de-prensa/2024/precioneativoenergia010424>. Comunicado de prensa.
- [22] Ontañón, S. (2020). An overview of distance and similarity functions for structured data. *Artificial Intelligence Review*, 53:5309–5351.
- [23] Pradera, A., Beliakov, G., Bustince, H., and Baets, B. D. (2016). A review of the relationships between implication, negation and aggregation functions from the point of view of material implication. *Information Sciences*, 329:357–380.
- [24] Quevedo, J. M. M. (2002). *Introducción a la teoría de conjuntos*. Universidad Nacional de Colombia, Departamento de Matemáticas.
- [25] Rico, N., Huidobro, P., Bouchet, A., and Díaz, I. (2022). Similarity measures for interval-valued fuzzy sets based on average embeddings and its application to hierarchical clustering. *Information Sciences*, 615:794–812.
- [26] Shi, Y., Ruan, D., and Kerre, E. (2007). On the characterizations of fuzzy implications satisfying  $i(x,y)=i(x,i(x,y))$ . *Information Sciences*, 177(14):2954–2970.
- [27] Silva, P. (2019). *Scalable Models for Probabilistic Forecasting with Fuzzy Time Series*. PhD thesis.
- [28] Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3):338–353.